

中图分类号:

论文编号:



专业硕士学位论文

面向边缘异构场景的差异感知联邦学习方法研究

作者姓名 朱旭

专业学位类别 电子信息

专业学位领域 计算机技术

指导教师 陈彦明

Dissimilarity-Aware Federated Learning for Heterogeneous Edge Environments

A Dissertation Submitted for the Degree of Master

Candidate : ZHU Xu

Supervisor: CHEN Yanming

中图分类号:

论文编号:

硕 士 学 位 论 文

面向边缘异构场景的差异感知联邦学习方法研究

作者姓名	朱旭	申请学位级别	工程硕士
指导教师姓名	陈彦明	职 称	副教授
专业名称	计算机技术	研究方向	边缘计算
学习时间自	2023 年 09 月 17 日	起至	2026 年 06 月 23 日止
论文提交日期	2026 年 05 月 20 日	论文答辩日期	2026 年 05 月 10 日

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的
研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其
他人已经发表或撰写过的研究成果，也不包含为获得安徽大学或其他教育机构的
学位或证书而使用过的材料。本人切实履行人工智能使用主体第一责任人职责，
对学位论文的所有内容负最终责任。学位论文中使用人工智能生成、合成的内容
(如文本、图片、音频、视频、虚拟场景等)，已根据实际情况添加显式标识或
隐式标识。如有学术不端行为，一切后果由本人承担，与导师和安徽大学无关。

学位论文作者签名：



签字日期：2026 年 5 月 20 日

学位论文版权使用授权书


本学位论文作者完全了解安徽大学有关保留、使用学位论文的规定，有权
保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。
本人授权安徽大学可以将学位论文的全部内容编入有关数据库进行检索，
可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密的学位论文在解密后适用本授权书)

学位论文作者签名：



导师签名：



签字日期：2026 年 5 月 20 日

签字日期：2026 年 5 月 20 日

摘 要

随着物联网、智能交通和工业互联网等场景的持续发展，大量数据分散存储在边缘终端中。受数据隐私、通信成本和设备资源约束影响，传统集中式机器学习方法难以直接适用于此类分布式边缘环境。联邦学习能够在不汇聚原始数据的前提下实现多客户端协同建模，为物联网边缘智能提供了一种可行方案。然而，在真实边缘场景中，不同客户端的数据通常同时存在标签分布偏斜和样本量偏斜，形成双偏斜非独立同分布 (Non-IID) 问题，进而导致全局模型收敛不稳定、客户端更新方向差异增大以及模型精度下降。现有非 IID 联邦学习优化方法多针对单一异构因素展开，部分方法还需要引入额外模型结构或改变训练流程，在资源受限的边缘节点上部署成本较高。

针对上述问题，本文围绕边缘异构场景下的差异感知联邦学习方法展开研究，提出一种可插拔的客户端配对互约束框架 FCPC (Federated Client Pairing and Mutual Constraint)。该框架首先构建 JSDN (Jensen-Shannon Divergence and Skew Indicator Number) 指标，用于统一刻画客户端之间由标签分布和样本量共同造成的数据差异；在此基础上，依据客户端差异度进行配对，并在本地训练过程中引入轻量级互约束项，使高差异客户端的更新方向形成一定约束，从而缓解双偏斜 Non-IID 条件下的模型性能衰减问题。本文进一步对 FCPC 的收敛性、模块有效性和工程适配性进行了分析与实验验证。

本文的主要工作包括以下两个方面：

(1) 面向双偏斜 Non-IID 数据下的联邦学习性能退化问题，提出基于差异感知的 FCPC 基础框架。本文通过实验分析客户端间数据差异与互约束效果之间的关系，设计能够同时反映标签分布偏斜和样本量偏斜的 JSDN 指标，并构建基于高差异客户端配对的正则化约束机制。基于 MNIST、FEMNIST、CIFAR-10 和 CIFAR-100 等数据集的实验结果表明，在典型双偏斜异构场景下，FCPC 能够提升全局模型分类性能。其中，在 CIFAR-10 极端异构设置下，FCPC 的 Top-1 分类精度达到 63.17%，较 FedAvg 基线提升 9.4 个百分点。

(2) 面向联邦学习方法在边缘场景中的工程化适配需求，进一步验证 FCPC 的可插拔性、鲁棒性和资源开销。本文将 FCPC 分别与 FedAvg、FedProx、MOON 等主流联邦学习算法结合，实验结果显示其能够在不同基线方法上带来 3.5%-9.4% 的性能提升；通

过消融实验分析 JSDN 指标、客户端配对策略和约束强度等关键模块对性能的影响；同时补充通信开销、计算复杂度和边缘资源占用分析，说明 FCPC 不改变全局模型结构，主要额外开销集中在服务器端配对计算和少量客户端元信息传输。最后，本文以智能交通车路协同场景为例，设计 FCPC 的场景化部署流程，并基于轻量级交通仿真实验分析其在边缘客户端中的运行开销。实验与分析结果表明，FCPC 在保持较低端侧资源占用的同时，能够为双偏斜 Non-IID 边缘场景下的联邦学习优化提供有效支撑。

关键词：联邦学习，非独立同分布，边缘异构，物联网，客户端配对

Abstract

With the development of the Internet of Things, intelligent transportation, and industrial Internet, a large amount of data is generated and stored on distributed edge devices. Due to privacy requirements, communication costs, and limited device resources, conventional centralized machine learning is difficult to apply directly in such edge environments. Federated learning provides a feasible paradigm for collaborative model training without collecting raw data from clients. However, in practical edge scenarios, local data on different clients often suffer from both label distribution skew and sample quantity skew, leading to dual-skew Non-IID data. Such heterogeneity may cause unstable convergence, divergent client updates, and degraded global model accuracy. Existing optimization methods for Non-IID federated learning usually focus on a single type of data heterogeneity, and some of them require additional model structures or modifications to the training process, which increases deployment costs on resource-constrained edge devices.

To address these issues, this thesis studies dissimilarity-aware federated learning for heterogeneous edge scenarios and proposes a pluggable framework named FCPC, namely Federated Client Pairing and Mutual Constraint. FCPC first constructs a unified metric named JSDN, short for Jensen-Shannon Divergence and Skew Indicator Number, to measure client-level data dissimilarity caused by both label distribution skew and sample quantity skew. Based on this metric, clients with relatively large data differences are paired, and a lightweight mutual constraint term is introduced during local training. In this way, the updates of highly dissimilar clients can be regularized to alleviate performance degradation under dual-skew Non-IID conditions. The convergence property, module effectiveness, and engineering adaptability of FCPC are further analyzed and evaluated.

The main contributions of this thesis are as follows.

- (1) To improve federated learning performance under dual-skew Non-IID data, a dissimilarity-aware FCPC framework is proposed. This thesis analyzes the relationship between client-level data dissimilarity and mutual constraint effects, designs the JSDN metric to jointly characterize label distribution skew and sample quantity skew, and constructs a regularization

mechanism based on high-dissimilarity client pairing. Experiments on MNIST, FEMNIST, CIFAR-10, and CIFAR-100 show that FCPC improves the classification performance of the global model in typical dual-skew heterogeneous settings. In an extreme heterogeneous setting on CIFAR-10, FCPC achieves a Top-1 accuracy of 63.17%, outperforming the FedAvg baseline by 9.4 percentage points.

(2) To evaluate the engineering adaptability of the proposed method in edge scenarios, the pluggability, robustness, and resource overhead of FCPC are further investigated. FCPC is integrated with several representative federated learning algorithms, including FedAvg, FedProx, and MOON. Experimental results show that FCPC brings performance improvements of 3.5%-9.4% across different baselines. Ablation studies are conducted to analyze the effects of the JSDN metric, client pairing strategy, and constraint strength. In addition, communication overhead, computational complexity, and edge resource consumption are analyzed, showing that FCPC does not change the global model structure and mainly introduces extra costs in server-side pairing computation and lightweight client metadata transmission. Finally, a scenario-oriented deployment workflow is designed for an intelligent transportation vehicle-road collaboration scenario, and a lightweight traffic simulation is conducted to evaluate the runtime overhead on edge clients. The experimental and analytical results indicate that FCPC can support federated learning optimization in dual-skew Non-IID edge scenarios while maintaining relatively low client-side resource consumption.

Key words: Federated learning, Non-IID data, Edge heterogeneity, Internet of Things, Client pairing

目 录

第一章 绪论	1
1.1 研究背景与意义	1
1.1.1 产业发展背景	1
1.1.2 核心学术痛点	2
1.1.3 本文的理论意义与工程价值	2
1.2 国内外研究现状	3
1.2.1 联邦学习非 IID 问题研究进展	3
1.2.2 IoT 场景联邦学习落地研究现状	4
1.2.3 现有研究的不足与本文研究切入点	5
1.3 本文研究内容与技术路线	6
1.3.1 双偏斜数据异构性量化与基础框架设计	6
1.3.2 IoT 场景的框架兼容性验证与落地适配优化	6
1.4 本文组织结构	7
1.5 本章小结	8
第二章 相关技术与理论基础	9
2.1 联邦学习核心定义与标准范式	9
2.1.1 联邦学习的核心定义与系统架构	9
2.1.2 经典 FedAvg 算法流程与优化目标	10
2.2 非 IID 数据异构性理论与挑战	11
2.2.1 非 IID 数据的分类与核心特征	11
2.2.2 双偏斜非 IID 数据的性能影响机理	12
2.3 差分隐私与本地差分隐私基础理论	12
2.3.1 差分隐私核心定义与实现机制	12
2.3.2 本地差分隐私的原理与应用规范	13
2.4 联邦学习主流基线算法详解	14
2.4.1 正则化类基线算法	15
2.4.2 对比学习与知识蒸馏类基线算法	16
2.5 本章小结	16

第三章 双偏斜数据异构量化与基础框架设计	18
3.1 研究动机与问题形式化定义	18
3.1.1 双偏斜非 IID 数据的性能影响实验分析	18
3.1.2 客户端差异度与约束效应的关联验证	19
3.1.3 核心问题形式化定义	21
3.2 双偏斜异构性统一量化指标 JSDN 设计	22
3.2.1 标签分布偏斜量化方法	22
3.2.2 样本量偏斜量化方法	23
3.2.3 JSDN 融合指标设计与特性分析	24
3.3 基于 JSDN 的客户端配对算法设计	24
3.3.1 基于 LDP 的隐私保护数据上传机制	24
3.3.2 JSDN 矩阵构建与配对算法实现	25
3.3.3 客户端数量奇偶性适配方案	26
3.4 FCPC 基础框架与配对约束机制设计	26
3.4.1 配对正则化项设计与优化目标构建	26
3.4.2 FCPC 完整训练流程与系统架构	28
3.5 基础框架收敛性理论分析	29
3.5.1 收敛性分析前提假设	29
3.5.2 核心引理与收敛性定理	30
3.6 基础框架核心性能实验验证	31
3.6.1 实验环境与基础参数设置	31
3.6.2 单类型非 IID 场景性能验证	32
3.6.3 双偏斜非 IID 场景性能验证	33
3.7 本章小结	34
第四章 框架的正交性优化与 IoT 场景落地	35
4.1 研究动机与优化目标	35
4.2 FCPC 框架与主流 FL 算法的正交性验证	36
4.2.1 正交性设计原理与融合方案	36
4.2.2 实验设置	37
4.2.3 实验结果与深度分析	37

4.3 FCPC 框架核心模块消融实验与鲁棒性分析	39
4.3.1 JSDN 权重参数 λ 的消融实验	39
4.3.2 正则化系数 β 的消融实验	40
4.3.3 差异度量化指标的对比消融实验	42
4.3.4 极端异构场景鲁棒性分析	43
4.4 通信开销、计算复杂度与边缘资源占用分析	44
4.5 面向智能交通场景的部署设计与可行性分析	45
4.5.1 智能交通 IoT 场景的设备与双偏斜数据特征	46
4.5.2 FCPC 框架的场景化部署架构与全流程	47
4.5.3 智能交通场景仿真实验	48
4.5.4 场景落地适配优势与应用价值	50
4.6 本章小结	50
第五章 总结与展望	52
5.1 本文工作总结	52
5.2 未来研究展望	53
参考文献	54
攻读硕士学位期间取得的学术成果	61
致 谢	62

图 清 单

图 1.1 边缘异构场景	1
图 1.2 章节关系图	7
图 2.1 非独立同分布数据场景分类	11
图 3.1 不同场景下 FedAvg 算法的分类精度变化曲线	19
图 3.2 不同配对场景下模型奇异值的对数分布曲线	20
图 3.3 FCPC 框架	28
图 3.4 单类型非 IID 场景下基于 MNIST 系列数据集算法精度	32
图 3.5 双偏斜非 IID 场景下基于 CIFAR 系列数据集算法精度	33
图 4.1 FCPC 框架与主流联邦学习算法的正交性	38
图 4.2 λ 消融实验	40
图 4.3 β 消融实验 (CIFAR-10)	41
图 4.4 β 消融实验 (CIFAR-100)	41
图 4.5 不同量化指标的分类精度对比	43
图 4.6 智能交通 IoT 场景	46
图 4.7 FCPC 交通应用架构	47

List of Figures

Fig. 1.1 Edge heterogeneous scene	1
Fig. 1.2 Chapter Relationship	7
Fig. 2.1 Non-IID data scene classification	11
Fig. 3.1 Classification accuracy variation curve of FedAvg algorithm in different scenarios	19
Fig. 3.2 Logarithmic distribution curves of model singular values in different pairing scenarios	20
Fig. 3.3 FCPC framework	28
Fig. 3.4 Accuracy of algorithms based on MNIST series dataset in single type Non-IID scenarios	32
Fig. 3.5 Accuracy of algorithms based on CIFAR series dataset in dual skewed Non-IID scenarios	33
Fig. 4.1 The orthogonality between FCPC framework and mainstream federated learning algorithms	38
Fig. 4.2 λ ablation experiment	40
Fig. 4.3 β ablation experiment (CIFAR-10)	41
Fig. 4.4 β ablation experiment (CIFAR-100)	41
Fig. 4.5 Comparison of classification accuracy of different quantitative indicators	43
Fig. 4.6 Intelligent transportation IoT scenarios	46
Fig. 4.7 FCPC transportation application architecture	47

表 清 单

表 3.1 单类型非 IID 场景下 MNIST 与 FEMNIST 数据集的测试精度	32
表 3.2 不同异构程度双偏斜场景下 CIFAR-10 数据集的性能对比	33
表 3.3 不同异构程度双偏斜场景下 CIFAR-100 数据集的性能对比	34
表 4.1 CIFAR-10 数据集上 FCPC 与主流 FL 算法的正交性验证结果 (ResNet-18) ·	37
表 4.2 TinyImageNet 数据集上 FCPC 与主流 FL 算法的正交性验证结果	39
表 4.3 不同差异度量化指标的性能对比 ($\alpha = 0.5$)	42
表 4.4 不同联邦学习方法的额外开销对比	45
表 4.5 不同交通边缘模型规模下的通信量估算	45
表 4.6 智能交通场景下 FCPC 的资源开销估算	49

List of Tables

Table 3.1	Test accuracy of MNIST and FEMNIST datasets under single-type non-IID scenarios	32
Table 3.2	Performance comparison of CIFAR-10 dataset under double-skew non-IID scenarios with different heterogeneity degrees	33
Table 3.3	Performance comparison of CIFAR-100 dataset under double-skew non-IID scenarios with different heterogeneity degrees	34
Table 4.1	Orthogonality verification results of FCPC and mainstream FL algorithms on CIFAR-10 dataset (ResNet-18)	37
Table 4.2	Orthogonality verification results of FCPC and mainstream FL algorithms on TinyImageNet dataset	39
Table 4.3	Performance comparison of different dissimilarity quantification metrics ($\alpha = 0.5$)	42
Table 4.4	Comparison of extra overhead among different federated learning methods	45
Table 4.5	Communication estimation under different traffic edge model scales	45
Table 4.6	Resource overhead estimation of FCPC in the intelligent transportation scenario	49

第一章 绪论

1.1 研究背景与意义

1.1.1 产业发展背景

物联网技术的规模化落地，推动工业生产、城市治理、民生服务等领域进入数据驱动的智能化转型阶段。截至当前，全球物联网终端设备接入量已突破百亿级，其中工业传感器、车载智能终端、路侧感知设备、医疗监测设备等边缘节点（如图1.1）持续产生海量高价值的场景化数据，成为人工智能模型迭代与智能服务落地的核心生产资料^[1, 2]。




图 1.1 边缘异构场景

Fig. 1.1 Edge heterogeneous scene

与此同时，全球范围内的数据隐私合规体系日趋完善，我国《数据安全法》《个人信息保护法》明确要求，个人信息与敏感工业数据的处理需遵循“数据本地化”“最小必要”原则，严禁跨主体的原始数据集中汇聚与无授权流转^[3]。传统集中式机器学习需要将多源数据统一上传至中心服务器完成训练，不仅面临极高的隐私泄露风险，还会产生海量的跨节点数据传输开销，与物联网场景的隐私合规要求、边缘节点资源特性完全相悖。

在此背景下，联邦学习作为一种新兴的分布式机器学习范式，成为破解物联网场景“数据孤岛”与“隐私保护”矛盾的核心技术。联邦学习的核心逻辑是：多参与方在不

泄露本地原始数据的前提下，仅通过交互模型参数或梯度信息，协同完成全局模型的训练，实现“数据不动模型动”的隐私保护训练模式。该范式与物联网边缘节点的隐私保护需求较为契合，已在工业设备故障诊断、智能交通车路协同、智慧健康监测等场景完成初步落地验证^[4]，成为物联网场景智能化升级的关键支撑技术。

1.1.2 核心学术痛点

经典联邦学习算法的性能收敛，高度依赖“各参与方本地数据服从独立同分布”的强假设。但在真实物联网场景中，边缘终端的部署环境、感知能力、业务场景存在本质差异，本地数据普遍存在严重的非独立同分布（Non-IID）特性^[5]，其中最典型、对模型性能影响最显著的，是标签分布偏斜与样本量偏斜共存的双偏斜异构场景：一方面，不同终端的采集目标与场景不同，导致数据的标签分布存在显著差异，例如城市路口的交通摄像头采集的拥堵类样本占比，远高于郊区路段的同类型设备；另一方面，不同终端的部署时长、开机频率、存储能力存在差异，导致本地样本量差距可达数个数量级，例如高频运行的工业传感器样本量，远低于间歇式工作的环境监测终端^[6]。

现有研究与实验验证已表明，单一类型的标签偏斜或样本量偏斜，已会导致联邦学习全局模型出现梯度发散、收敛速度变慢、分类精度下降等问题；而双偏斜异构场景下，两种偏斜的耦合效应会进一步放大模型性能的衰减幅度，甚至导致模型完全无法收敛，成为制约联邦学习在物联网场景规模化落地的核心瓶颈。

当前学术界针对非 IID 联邦学习的优化研究，仍存在三个无法适配物联网场景需求的核心痛点：其一，多数研究仅针对单一类型的非 IID 偏斜设计优化方案，缺乏对双偏斜耦合场景的针对性优化，在真实物联网场景中的性能提升效果有限；其二，现有优化方案大多通过引入对比学习、图结构建模、因果推断等复杂机制提升模型性能，带来了不可忽视的计算与通信开销，无法适配物联网边缘节点算力、存储、带宽资源受限的硬件特性；其三，多数方案需要修改联邦学习的核心聚合机制、模型架构或训练流程，与现有工业级联邦学习框架的兼容性极差，落地部署需要对现有系统进行大规模改造，落地成本极高，无法实现快速规模化应用。

1.1.3 本文的理论意义与工程价值

针对上述产业刚需与学术痛点，本文以物联网双偏斜非 IID 场景为研究对象，开展轻量级、高兼容性的联邦学习优化方法研究，具备显著的理论意义与工程价值。

在理论层面,本文针对双偏斜非 IID 这一核心痛点,挖掘并验证了客户端数据分布差异与模型收敛性之间的内在关联,提出了能够同时刻画标签分布偏斜与样本量偏斜的统一量化指标,构建了基于客户端互约束效应的轻量级优化框架,丰富了非 IID 联邦学习的理论体系,填补了现有研究在双偏斜异构场景量化与优化领域的研究空白。

在工程层面,本文设计的优化方案具备即插即用的核心特性,无需修改现有主流联邦学习算法的核心架构与训练流程,仅引入轻量级配对正则化项,即可实现模型性能的稳定提升,与物联网边缘节点的资源受限特性较为匹配。同时,本文结合智能交通车路协同这一典型物联网场景,完成了方案的场景化部署设计、开销分析与轻量级仿真支撑,为联邦学习在物联网场景中的进一步部署提供低改造成本的可行方案。

1.2 国内外研究现状

1.2.1 联邦学习非 IID 问题研究进展

自 2017 年 McMahan 等人提出经典 FedAvg 算法,奠定横向联邦学习的基础范式以来,非 IID 数据导致的模型性能衰减问题,始终是联邦学习领域的核心研究热点。当前国内外相关研究,主要可分为算法优化、架构创新、时空特性挖掘三大类,各类研究均形成了阶段性成果,但仍存在适配双偏斜场景的固有缺陷^[7-9]。

第一类是基于算法优化的改进方案,该类方案主要从本地训练优化与全局聚合机制优化两个维度,缓解非 IID 数据带来的梯度发散问题^[10-12]。本地训练优化方向的代表性工作中, FedProx^[13] 算法在本地损失函数中引入近端项,限制本地模型更新与全局模型的偏差幅度,一定程度上缓解了非 IID 场景下的梯度发散问题;但该算法的近端项权重难以实现自适应调整,在强双偏斜场景下,约束过强会限制模型对本地特征的有效学习,约束过弱则无法起到梯度对齐的效果,性能提升存在明显瓶颈。MOON^[14] 算法将对比学习引入联邦训练流程,通过对齐本地模型、全局模型与上一轮本地模型的特征表示,缓解非 IID 带来的特征分布偏移;但该方案需要额外的特征提取与对比损失计算,引入了大量的计算开销,无法适配资源受限的边缘设备。FedDyn^[15] 算法通过动态知识蒸馏机制提取各客户端的可靠本地知识,采用焦点蒸馏策略缓解多客户端的知识偏差问题;但该方案需要修改 FedAvg 的全局平均聚合策略,与现有联邦学习框架的兼容性较差。

全局聚合机制优化方向的研究，主要通过改进客户端权重分配策略，缓解非 IID 数据带来的聚合偏差。例如 FedCFA^[16] 算法通过反事实推理，修正非 IID 数据导致的辛普森悖论，优化全局聚合的权重分配；FBLG^[17] 算法为每个客户端构建本地图结构，通过图聚合缓解双偏斜非 IID 带来的性能衰减。但这类方案普遍需要引入复杂的权重建模或图结构计算，不仅带来了极高的计算开销，还需要对全局聚合流程进行深度改造，落地难度极大。

第二类是基于架构创新的改进方案，该类方案通过重构联邦学习的训练架构或模型结构，适配非 IID 数据的分布特性。代表性工作中，SplitFed^[18-21] 算法将联邦学习与拆分学习相结合，把模型拆分为客户端侧的浅层特征提取模块与服务器侧的深层推理模块，通过拆分训练缓解非 IID 带来的分布偏移；但该方案需要对模型结构进行定制化拆分，高度依赖特定的模型架构，无法适配通用的联邦学习场景。还有部分研究将 Vision Transformer 等大模型架构引入联邦学习^[22-24]，通过大模型的强特征提取能力缓解非 IID 问题；但这类模型参数量巨大，推理与训练的计算开销极高，完全无法在物联网边缘终端上部署。

第三类是基于时空特性挖掘的改进方案，该类方案主要针对时序数据的时空关联特性，挖掘数据的分布规律，缓解非 IID 带来的性能衰减。例如 DecFFD^[25] 算法针对跨地域设备故障诊断场景，挖掘数据的季节性波动规律，实现个性化联邦模型训练；但这类方案仅适用于具备时序特性的特定场景，无法处理物联网场景中普遍存在的静态标签与样本量双偏斜问题，泛化能力有限。

1.2.2 IoT 场景联邦学习落地研究现状

物联网场景的核心特征，可总结为四个维度：边缘终端数量庞大、单节点算力/存储/带宽资源严重受限、多节点数据异构性较强、工业与个人数据的隐私合规要求较高^[26]。这四大特征决定了，面向物联网场景的联邦学习方案，需要同时满足轻量级、低开销、高兼容性、强隐私保护四大核心要求^[27-30]。

当前国内外针对物联网场景的联邦学习落地研究，已覆盖多个核心垂直领域。在工业物联网领域，相关研究将联邦学习应用于轴承负载评估、工业设备故障诊断、齿轮磨损预测等场景，实现多工业终端的协同模型训练，避免工业敏感数据的泄露；在智能交通领域，基于车路协同架构的联邦学习方案^[31-34]，通过路侧单元与车载单元的协同训

练,实现交通流量预测、信号配时优化、突发事故识别等应用,提升交通系统的运行效率;在绿色物联网领域, FastPPO^[35] 算法通过强化学习实现客户端的自适应调度,适配物联网终端的动态资源特性,在优化模型精度的同时,降低终端的训练能耗^[36]。

但现有物联网场景的联邦学习落地研究,仍存在三个核心短板:其一,多数研究默认场景内数据仅存在单一类型的非 IID 偏斜,没有针对物联网场景中普遍存在的标签与样本量双偏斜耦合场景进行针对性优化,在真实场景中的性能表现远不及实验室环境;其二,多数方案为了提升模型性能,引入了大量额外的计算与通信开销,与物联网边缘终端的资源受限特性完全相悖,无法在真实硬件上完成部署^[37-39];其三,现有方案大多为特定场景定制化设计,需要修改联邦学习的核心训练流程,与 FATE、FedML 等主流工业级联邦学习框架兼容性极差,跨场景迁移与规模化落地的改造成本极高。

1.2.3 现有研究的不足与本文研究切入点

综合上述国内外研究现状,当前非 IID 联邦学习研究,尤其是面向物联网场景的落地方案,仍存在三个核心的研究缺口,也是本文的核心研究切入点:

第一,双偏斜异构性的量化缺口。现有研究大多针对单一类型的非 IID 偏斜设计优化方案,缺乏能够同时刻画标签分布偏斜与样本量偏斜的统一量化指标,无法精准表征物联网场景中普遍存在的双偏斜异构性,导致后续的优化方案缺乏精准的量化依据,优化效果存在明显瓶颈。

第二,方案轻量化的适配缺口。现有针对双偏斜非 IID 的优化方案,大多引入了图结构构建、对比学习、因果建模等复杂机制,带来了不可忽视的计算与存储开销,无法适配物联网边缘终端的资源受限特性,难以在真实场景中完成部署^[40]。

第三,落地兼容性的设计缺口。现有多数优化方案,需要修改联邦学习的核心聚合机制、模型架构或训练流程,与现有主流联邦学习框架的兼容性极差,需要对现有系统进行大规模改造,落地成本极高,无法实现即插即用的快速规模化部署。

针对上述三个核心研究缺口,本文以物联网双偏斜非 IID 场景为研究对象,首先挖掘客户端数据分布差异与模型收敛性的内在关联,设计双偏斜异构性的统一量化指标与轻量级客户端配对约束机制,构建基础优化框架并验证其有效性;随后完成框架与现有主流算法的正交性验证、鲁棒性分析、开销分析与物联网场景化部署设计,形成一套面向双偏斜非 IID 联邦学习的低改造成本优化方案。

1.3 本文研究内容与技术路线

本文围绕物联网场景中，双偏斜非 IID 数据导致的联邦学习模型性能衰减这一核心问题，开展了两项递进式的研究工作，形成了“现状调研-理论分析-方法设计-性能验证-落地适配”的完整研究闭环，整体技术路线清晰可控^[41, 42]。

1.3.1 双偏斜数据异构性量化与基础框架设计

本项工作的核心目标，是解决双偏斜非 IID 数据导致的联邦学习梯度发散、维度坍塌、性能衰减问题，完成基础优化方法设计。核心研究内容包括：1. 通过多组对照预实验，分析双偏斜非 IID 数据对联邦学习模型性能的影响机理，挖掘客户端数据分布差异与模型收敛性之间的内在关联，明确互约束效应的存在性与作用规律；2. 针对双偏斜异构性的量化缺口，设计能够同时刻画标签分布偏斜与样本量偏斜的统一量化指标，实现对双偏斜异构性的整体表征；3. 基于上述量化指标，设计最大化分布差异的客户端配对算法，结合轻量级正则化约束机制，构建完整的联邦学习基础优化框架，完成框架的收敛性理论分析与证明；4. 在 MNIST、FEMNIST、CIFAR-10/100 等标准数据集上，完成框架的核心性能验证，与 FedAvg、FedProx、MOON 等主流基线算法进行对比，验证方案在单偏斜与双偏斜场景下的有效性。

本项工作的核心创新点在于，揭示了客户端数据分布差异与互约束效应的正相关关系，提出了双偏斜异构性的统一量化方法，设计了轻量级的配对约束优化框架，从根源上缓解了双偏斜场景下的模型性能衰减问题。

1.3.2 IoT 场景的框架兼容性验证与落地适配优化

本项工作的核心目标，是分析基础框架在物联网场景中应用时的兼容性、鲁棒性和部署开销，验证方案的工程可行性。核心研究内容包括：1. 针对现有方案的落地兼容性缺口，验证基础框架与现有主流联邦学习算法的正交兼容性，完成多算法、多数据集、多异构度的对照实验，验证方案的即插即用特性；2. 通过多组消融实验，分析框架核心模块的有效性，以及关键超参数对模型性能的影响规律，明确全场景适配的最优超参数取值；3. 通过极端异构场景、多客户端数量、多模型架构的对照实验，验证框架在复杂场景下的鲁棒性与泛化能力；4. 结合智能交通车路协同这一典型物联网场景，分析场景内的双偏斜数据特征，完成框架的场景化部署流程设计，并通过轻量级仿真实验补充通信、计算与资源占用分析。

本项工作的核心创新点在于，验证了框架的即插即用核心特性，无需修改现有联邦学习算法的核心架构，即可实现稳定的性能提升；同时完成了物联网场景的部署适配设计与开销分析，为方案的后续工程验证提供参考。

1.4 本文组织结构

本文共设置 5 个核心章节，各章节的核心内容与逻辑递进关系如下图 1.2 所示：




图 1.2 章节关系图

Fig. 1.2 Chapter Relationship

第 1 章为绪论，本章阐述了本文的研究背景与产业刚需，系统梳理了非 IID 联邦学习与物联网场景落地的国内外研究现状，明确了现有研究的核心缺口与本文的研究切入点，介绍了本文两项递进式的核心研究内容与技术路线，最后给出全文的组织结构。

第 2 章为相关技术与理论基础，本章系统阐述了联邦学习的核心定义、标准范式与经典算法，分析了非 IID 数据异构性的核心特征与对模型性能的影响机理，讲解了差分隐私与本地差分隐私的核心理论与实现机制，同时对本文用到的主流基线算法进行了详细介绍，为后续的方法设计与实验验证提供坚实的理论基础。

第 3 章为面向双偏斜非 IID 的异构性量化与基础框架设计，是本文的第一项研究工作。本章首先通过预实验分析双偏斜非 IID 数据的性能影响机理，挖掘客户端数据分布

差异与互约束效应的内在关联，完成核心问题的形式化定义；随后设计双偏斜异构性的统一量化指标，基于该指标完成客户端配对算法的设计；在此基础上，构建完整的基础优化框架与配对约束机制，完成框架的收敛性理论分析；最后通过标准数据集上的核心性能实验，验证基础框架的有效性。

第4章为框架的正交性验证与IoT场景落地优化，是本文的第二项研究工作。本章首先明确了物联网场景工程落地的核心痛点与本章的优化目标；随后通过多数据集、多算法的对照实验，验证框架与现有主流联邦学习算法的正交兼容性；通过消融实验与敏感性分析，验证框架核心模块的有效性与超参数的最优取值规律；通过极端异构场景的实验，验证框架的鲁棒性；最后补充通信开销、计算复杂度与边缘资源占用分析，并结合智能交通车路协同IoT场景，完成框架的场景化部署设计与可行性分析。

第5章为总结与展望，本章系统总结了本文的两项核心研究工作与创新成果，梳理了本文的核心实验结论与研究价值，同时针对本文研究的局限性，提出了未来可延伸的研究方向。

1.5 本章小结

本章围绕物联网场景双偏斜非IID联邦学习的核心研究主题，首先从产业发展刚需、学术研究痛点两个维度，阐述了本文的研究背景与理论、工程价值；随后系统梳理了非IID联邦学习与物联网场景落地的国内外研究现状，明确了现有研究在异构性量化、方案轻量化、落地兼容性三个维度的核心缺口；在此基础上，介绍了本文两项递进式的核心研究内容与完整技术路线；最后明确了全文的组织结构与各章节的逻辑关系。下一章将系统阐述本文研究内容涉及的相关技术与理论基础，为后续的方法设计与实验验证提供理论支撑。

第二章 相关技术与理论基础

本章系统梳理本文研究涉及的核心基础理论与主流技术方案，为后续的方法设计、理论分析与实验验证提供完整的理论支撑与基准对比依据。首先阐述联邦学习的核心定义、标准范式与经典基准算法；其次分析非独立同分布数据的异构性分类与对联邦学习模型的性能影响机理；随后讲解差分隐私与本地差分隐私的核心理论与实现机制，明确本文隐私保护方案的理论基础；最后详细拆解本文实验用到的主流基线算法的核心思路、实现流程与固有局限性，为后续的性能对比实验建立统一的基准框架。

2.1 联邦学习核心定义与标准范式

2.1.1 联邦学习的核心定义与系统架构

联邦学习（Federated Learning, FL）是一种面向分布式数据场景的隐私保护机器学习范式，其核心思想是“数据不动模型动”：多个数据持有方（客户端）在不泄露本地原始数据的前提下，仅通过交互模型参数或梯度更新信息，协同完成全局机器学习模型的训练，从根源上规避了跨主体原始数据流转带来的隐私泄露风险。

从系统架构来看，经典横向联邦学习系统采用“中心服务器-多客户端”的双层架构，在物联网（Internet of Things, IoT）场景下，可进一步拓展为“云-边-端”三级协同架构，与本文研究场景的部署形态相匹配：

（1）端侧客户端：即物联网边缘终端，包括车载单元、路侧传感器、工业监测设备等，是本地数据的持有方，负责基于本地数据集完成模型的本地训练，仅向服务器上传模型更新信息，全程不泄露原始数据。

（2）边缘服务器：负责区域内终端设备的接入管理、模型预聚合与边缘推理，降低中心服务器的计算压力与跨区域通信开销，适配物联网场景的广域部署特性。

（3）中心云服务器：负责全局模型的初始化、分发、聚合与更新，协调所有客户端的协同训练流程，是联邦学习系统的调度核心。

按照数据分布特性与训练范式，联邦学习可分为横向联邦学习、纵向联邦学习与联邦迁移学习三大类。本文的研究对象为横向联邦学习，即各客户端的数据集共享相同的特征空间，但样本空间不同，这也是物联网感知场景中最普遍的联邦学习部署形态。

2.1.2 经典 FedAvg 算法流程与优化目标

联邦平均算法^[43] (Federated Averaging, FedAvg) 是横向联邦学习的基准算法, 也是本文所有方案设计与性能对比的核心基准, 其核心逻辑是通过客户端本地模型更新的加权平均, 完成全局模型的迭代更新。

形式化定义如下: 设联邦学习系统共有 n 个客户端, 第 i 个客户端的本地数据集为 D_i , 样本量为 $|D_i|$, 全系统总样本量为 $|D| = \sum_{i=1}^n |D_i|$ 。联邦学习的全局优化目标, 是最小化全局模型在所有客户端数据集上的加权经验损失, 数学表达式为:

$$\min_{\theta} \mathcal{L}(\theta) = \sum_{i=1}^n \frac{|D_i|}{|D|} \mathcal{L}_i(\theta) \quad (2-1)$$

其中, θ 为全局模型的参数, $\mathcal{L}_i(\theta)$ 为模型参数 θ 在第 i 个客户端本地数据集上的损失函数, 权重系数 $\frac{|D_i|}{|D|}$ 为客户端样本量占总样本量的比例, 样本量越大的客户端, 对全局模型更新的贡献权重越高。

FedAvg 算法的完整训练流程可分为 5 个核心步骤, 所有步骤均无需原始数据的跨客户端流转:

(1) 模型初始化: 中心服务器完成全局模型的参数初始化, 将初始模型参数 $\theta^{(0)}$ 分发至所有参与训练的客户端;

(2) 本地训练: 每一轮通信开始时, 服务器将当前轮次的全局模型参数 $\theta^{(t)}$ 分发至选中的客户端, 各客户端基于本地数据集完成固定轮次的本地迭代训练, 得到本地模型更新参数 $\theta_i^{(t)}$;

(3) 更新上传: 完成本地训练后, 各客户端将本地模型更新参数上传至中心服务器, 全程不传输任何原始训练数据;

(4) 全局聚合: 服务器基于各客户端的样本量权重, 对所有本地模型更新进行加权平均聚合, 得到更新后的全局模型参数, 聚合公式为:

$$\theta^{(t+1)} = \theta^{(t)} - \eta \sum_{i=1}^n \frac{|D_i|}{|D|} \nabla \mathcal{L}_i(\theta^{(t)}) \quad (2-2)$$

其中, $\theta^{(t)}$ 为第 t 轮的全局模型参数, η 为模型训练的学习率, $\nabla \mathcal{L}_i(\theta^{(t)})$ 为第 i 个客户端的本地损失函数梯度; (5) 模型分发: 服务器将更新后的全局模型参数 $\theta^{(t+1)}$ 分发至

所有客户端，进入下一轮通信迭代，直至模型收敛或达到预设的最大通信轮次。

FedAvg 算法奠定了横向联邦学习的基础范式，具备实现简单、部署门槛低、通信开销可控的优势，但其性能收敛高度依赖“各客户端本地数据服从独立同分布”的强假设。在非独立同分布场景下，该算法会出现梯度发散、收敛速度变慢、模型精度大幅下降等问题，这也是本文研究的核心痛点。

2.2 非 IID 数据异构性理论与挑战

2.2.1 非 IID 数据的分类与核心特征

非独立同分布（Non-Independent and Identically Distributed, Non-IID）数据，指的是联邦学习系统中，不同客户端的本地数据集在特征空间、标签空间或联合分布上存在显著差异，违背了 FedAvg 算法的独立同分布假设。在真实物联网场景中，边缘终端的部署环境、感知能力、业务场景存在本质差异，非 IID 数据是普遍存在的客观现象，也是制约联邦学习落地的核心瓶颈。

当前学术界将联邦学习中的非 IID 数据异构性分为五大类，本文重点关注其中两类最典型、对模型性能影响最显著的异构性，即标签分布偏斜^[44]与样本量偏斜，二者共存的场景被称为双偏斜非 IID 场景^[45]，也是本文的核心研究对象，如图2.1。




图 2.1 非独立同分布数据场景分类
Fig. 2.1 Non-IID data scene classification

(1) 标签分布偏斜：也被称为类别偏斜，指不同客户端的本地数据集共享相同的标签空间，但各类别样本的占比存在显著差异。例如在智能交通场景中，城市核心路口的交通摄像头采集的数据集里，拥堵类标签的样本占比可达 80% 以上，而郊区路段的同类型设备，正常通行类标签的样本占比超过 90%，二者的标签分布存在本质差异。

(2) 样本量偏斜：也被称为数量偏斜，指不同客户端的本地数据集的总样本量存在

数量级差异。在物联网场景中，高频运行的工业传感器、24 小时在线的交通摄像头，其本地样本量可达数十万条；而间歇式工作的环境监测终端、低功耗穿戴设备，其本地样本量可能仅数千条，二者的样本量差距可达两个数量级以上。

2.2.2 双偏斜非 IID 数据的性能影响机理

单一类型的标签分布偏斜或样本量偏斜，已会对联邦学习模型的收敛性与精度产生负面影响；而双偏斜场景下，两种异构性的耦合效应会进一步放大性能衰减幅度，甚至导致模型完全无法收敛。其核心影响机理可分为三个维度：

(1) 梯度更新方向发散：不同客户端的标签分布与样本量存在显著差异，导致各客户端的本地优化目标存在本质偏差。在本地训练过程中，各客户端的梯度更新方向会朝着各自本地数据的最优解前进，而非全局最优解；服务器加权聚合后，全局梯度会出现严重的方向偏移，导致模型收敛速度变慢，甚至陷入局部最优解，出现精度大幅下降的问题。

(2) 全局聚合偏差：FedAvg 算法采用样本量加权的聚合策略，样本量较大的客户端会在全局聚合中占据绝对主导地位，全局模型会快速拟合大样本客户端的数据分布，完全忽略小样本客户端的特征。在双偏斜场景下，大样本客户端往往同时存在极端的标签分布偏斜，最终导致全局模型出现严重的分类偏差，泛化能力大幅下降。

(3) 特征空间维度坍塌：非 IID 数据会导致联邦学习的全局模型与本地模型均出现维度坍塌现象，即模型的特征表示空间发生退化，奇异值快速衰减至 0，无法充分利用完整的表示空间区分不同类别的数据。在双偏斜场景下，不同客户端的特征分布差异被进一步放大，维度坍塌现象会更加严重，直接导致模型的特征提取能力失效，分类精度断崖式下降。

2.3 差分隐私与本地差分隐私基础理论

2.3.1 差分隐私核心定义与实现机制

差分隐私^[46] (Differential Privacy, DP) 是当前业界公认的、具备数学定义的隐私保护量化框架，其核心思想是：通过向数据或计算结果中添加适量的随机噪声，使得攻击者无法通过单条数据的变化推断出数据集中的个体信息，从而实现对个体隐私的保护。差分隐私的核心优势在于，其隐私保护强度具备可量化、可证明的特性，能够平衡隐私

保护与数据效用的关系。

差分隐私的严格数学定义如下：设存在两个仅相差一条数据的相邻数据集 D 与 D' ，对于一个随机机制 $\mathcal{M}$ ，若其在两个相邻数据集上的输出结果的概率分布满足：

$$Pr[\mathcal{M}(D) \in S] \leq e^\epsilon \cdot Pr[\mathcal{M}(D') \in S] \quad (2-3)$$

则称该随机机制 $\mathcal{M}$ 满足 ϵ -差分隐私。其中， S 为机制 $\mathcal{M}$ 所有可能输出的可测集合， $\epsilon > 0$ 为隐私预算，是衡量隐私保护强度的核心指标： ϵ 的取值越小，机制对相邻数据集的输出差异限制越严格，隐私保护强度越高，但对数据效用的影响也越大；反之， ϵ 取值越大，数据效用越高，但隐私保护强度越低。

为了实现差分隐私，需要根据目标函数的灵敏度，确定添加噪声的幅度。函数的 ℓ_1 -灵敏度定义为：对于任意两个相邻数据集 D 与 D' ，函数 $f: D \rightarrow \mathbb{R}^k$ 的灵敏度为：

$$\Delta_1 f = \max_{D \sim D'} \|f(D) - f(D')\|_1 \quad (2-4)$$

其中， $\|\cdot\|_1$ 为 ℓ_1 范数，灵敏度衡量了单条数据的变化对函数输出结果的最大影响幅度。

基于灵敏度的定义，最经典的差分隐私实现机制为拉普拉斯机制，其通过向函数输出结果中添加服从拉普拉斯分布的噪声，实现 ϵ -差分隐私，数学表达式为：

$$\mathcal{M}(D) = f(D) + Lap\left(\frac{\Delta_1 f}{\epsilon}\right) \quad (2-5)$$

其中， $Lap(\cdot)$ 为尺度参数为 $\frac{\Delta_1 f}{\epsilon}$ 的拉普拉斯分布，噪声的幅度与函数灵敏度成正比，与隐私预算成反比，完全符合差分隐私的量化逻辑。

2.3.2 本地差分隐私的原理与应用规范

传统中心化差分隐私需要一个可信的第三方数据聚合方，所有数据需先集中至可信第三方，再进行隐私保护处理，这与联邦学习“数据本地化”的核心原则相悖。因此，本文采用本地差分隐私^[47, 48] (Local Differential Privacy, LDP) 框架，实现客户端数据的隐私保护。

本地差分隐私的核心逻辑是：所有隐私保护操作均在客户端本地完成，客户端先对

需要上传的信息进行噪声扰动，再将扰动后的结果上传至服务器，服务器无需获取客户端的原始数据，也无需被信任，从根源上消除了数据上传过程中的隐私泄露风险^[49]。

本地差分隐私的严格数学定义如下：对于一个随机机制 $\mathcal{M}$ ，任意两条输入数据 v 与 v' ，以及机制的任意输出结果 y ，若满足：

$$\frac{Pr[\mathcal{M}(v) = y]}{Pr[\mathcal{M}(v') = y]} \leq e^\epsilon \quad (2-6)$$

则称该机制满足 ϵ -本地差分隐私。与中心化差分隐私相比，本地差分隐私将隐私保护的粒度从数据集级别细化到单条数据级别，无需可信第三方，适用于联邦学习的分布式架构。

在本文的研究场景中，客户端需要向服务器上传本地数据的标签分布与样本量信息，用于后续的异构性量化与客户端配对。为了保护这部分信息的隐私，本文采用基于拉普拉斯机制的本地差分隐私扰动方案，对标签分布向量与样本量分别进行扰动，公式如下：

$$\tilde{h}_k = h_k + (Lap(2/\epsilon_h))^C \quad (2-7)$$

$$\tilde{N}_k = N_k + Lap(1/\epsilon_N) \quad (2-8)$$

其中， h_k 为客户端 k 的原始标签分布向量， C 为分类任务的类别总数， N_k 为客户端 k 的原始样本量； ϵ_h 与 ϵ_N 分别为标签分布与样本量的隐私预算，总隐私预算满足 $\epsilon = \epsilon_h + \epsilon_N$ 。

为了平衡标签分布与样本量的隐私保护强度与数据效用，本文采用最优隐私预算分配策略，公式如下：

$$\epsilon_h^* = \epsilon \cdot \frac{\sqrt{C/N_k}}{\sqrt{C/N_k} + 1}, \quad \epsilon_N^* = \epsilon - \epsilon_h^* \quad (2-9)$$

该分配策略基于标签分布与样本量的灵敏度差异，自适应调整隐私预算分配比例，在总隐私预算固定的前提下，最小化扰动带来的总方差，实现隐私保护与数据效用的最优平衡。

2.4 联邦学习主流基线算法详解

为了建立统一的性能对比基准，本文选取了 4 种当前非 IID 联邦学习领域具有代表性的主流算法作为基线。本节详细拆解各算法的核心思路、实现流程与固有局限性，为

后续的实验对比与结果分析提供理论依据。

2.4.1 正则化类基线算法

2.4.1.1 FedAvg 算法

FedAvg 算法是本文所有实验的核心基准，其核心思路与实现流程已在 2.1.2 节详细阐述，此处不再赘述。该算法的核心优势是实现简单、部署门槛低、通信开销可控，是当前工业界应用最广泛的联邦学习算法；其核心局限性是对非 IID 数据的适配能力极差，在双偏斜场景下会出现严重的梯度发散与精度下降问题，无法适配物联网真实场景的部署需求。

2.4.1.2 FedProx 算法

FedProx^[13] 算法是针对 FedAvg 在非 IID 与系统异构场景下的优化方案，也是正则化类非 IID 联邦学习算法的代表性工作。其核心思路是：在客户端本地训练的损失函数中，加入一个近端项（Proximal Term），限制本地模型更新与当前全局模型的偏差幅度，避免不同客户端的模型更新出现过度发散，从而缓解非 IID 数据带来的性能衰减问题。

FedProx 的本地优化目标函数为：

$$\min_w \mathcal{L}_i(w) + \frac{\mu}{2} \|w - \theta^{(t)}\|^2 \quad (2-11)$$

其中， $\mathcal{L}_i(w)$ 为客户端本地的原始损失函数， $\theta^{(t)}$ 为第 t 轮的全局模型参数， μ 为近端项的权重系数，控制约束的强度。

FedProx 的核心优势是：仅在本地损失函数中加入近端项，无需修改全局聚合流程，实现简单，与 FedAvg 的兼容性较好，在轻度非 IID 场景下有明显的性能提升。其核心局限性包括：其一，近端项的权重系数 μ 需要手动调参，无法自适应不同异构程度的场景，在强双偏斜场景下，约束过强会限制模型对本地特征的学习，约束过弱则无法起到梯度对齐的效果；其二，仅能限制本地模型与全局模型的偏差，无法从根源上解决不同客户端之间的梯度方向发散问题，在极端异构场景下性能提升有限。

2.4.2 对比学习与知识蒸馏类基线算法

2.4.2.1 MOON 算法

MOON^[14] (Model-Contrastive Federated Learning) 算法是对比学习在非 IID 联邦学习领域的代表性应用，其核心思路是：将模型级对比学习引入联邦训练流程，通过最大化当前轮本地模型与全局模型的特征相似度，同时最小化当前轮本地模型与上一轮本地模型的特征相似度，引导不同客户端的模型学习到一致的特征表示，缓解非 IID 数据带来的特征分布偏移问题。

MOON 的核心优化目标是在原始交叉熵损失的基础上，加入一个模型级对比损失，通过对比学习对齐不同客户端的特征空间。其核心优势是：无需修改全局聚合流程，与 FedAvg 的兼容性较好，在各类非 IID 场景下的性能均优于 FedProx，是当前非 IID 联邦学习的重要基线之一。其核心局限性是：需要额外的特征提取、存储与对比损失计算，引入了不可忽视的计算开销，对于算力、存储资源严重受限的物联网边缘终端，部署难度较大，难以适配本文的研究场景。

2.4.2.2 FedDyn 算法

FedDyn^[15] 算法是基于动态知识蒸馏的非 IID 联邦学习优化方案，其核心思路是：为每个客户端构建代理数据集，通过动态知识蒸馏机制提取各客户端的可靠本地知识，摒弃传统的平均聚合策略，采用焦点蒸馏策略，对可靠度更高的本地知识赋予更高的权重，缓解多客户端之间的知识偏差问题，提升全局模型在非 IID 场景下的泛化能力。

FedDyn 的核心优势是：能够有效缓解多客户端的知识偏差，在标签分布偏斜场景下有稳定的性能提升。其核心局限性包括：其一，需要修改 FedAvg 的核心全局聚合流程，与现有工业级联邦学习框架的兼容性极差，落地部署需要对现有系统进行大规模改造，改造成本极高；其二，动态知识蒸馏与焦点权重计算会带来额外的计算与通信开销，无法适配物联网边缘终端的资源受限特性。

2.5 本章小结

本章系统梳理了本文研究涉及的核心基础理论与主流技术方案。首先阐述了联邦学习的核心定义、系统架构与经典 FedAvg 基准算法的完整流程，明确了本文研究的基

础范式；其次分析了 Non-IID 数据的异构性分类，重点阐述了双偏斜 Non-IID 数据对联邦学习模型的性能影响机理，明确了本文研究的核心痛点；随后讲解了差分隐私与本地差分隐私的核心理论、实现机制与最优预算分配策略，为本文的隐私保护方案提供了严格的理论支撑；最后详细拆解了本文实验用到的 4 种主流基线算法的核心思路、实现流程与固有局限性，建立了统一的性能对比基准。

本章梳理的所有理论与技术方案，均明确了现有算法在物联网双偏斜 Non-IID 场景下的核心短板：要么无法适配双偏斜耦合场景，要么带来了过高的计算开销，要么与现有框架兼容性差，无法实现即插即用的规模化部署。这些短板也正是本文研究的核心切入点，下一章将针对上述痛点，开展双偏斜异构性统一量化与基础优化框架的设计研究。

第三章 双偏斜数据异构量化与基础框架设计

本章为本文的第一研究工作，核心目标是围绕双偏斜非 IID 数据导致的联邦学习模型梯度发散、维度坍塌和性能衰减问题，设计异构性量化方法与基础优化框架。

3.1 研究动机与问题形式化定义

上一章的国内外研究现状分析表明，现有非 IID 联邦学习优化方案，普遍存在双偏斜场景适配性差、计算开销过高、落地兼容性不足的核心短板。为了明确双偏斜非 IID 数据对模型性能的影响机理，挖掘缓解性能衰减的核心规律，本节通过 4 组对照预实验，完成核心研究动机的验证，并给出核心问题的形式化定义。

3.1.1 双偏斜非 IID 数据的性能影响实验分析

为了量化不同类型非 IID 异构性对联邦学习模型性能的影响差异，本节以经典 FedAvg 算法为基准，设计对照预实验，对比单一标签分布偏斜、单一样本量偏斜、标签 + 样本量双偏斜三种场景下的模型收敛性能。

3.1.1.1 实验设计

实验设置 10 个参与训练的客户端，采用 MNIST 手写数字数据集作为训练数据，以分类 Top-1 精度作为核心评价指标，设置 3 组对照场景：

(1) 标签分布偏斜场景：所有客户端样本量一致，通过 Dirichlet 分布 $\alpha = 0.1$ 模拟标签分布的异构性；

(2) 样本量偏斜场景：所有客户端标签分布一致，样本量按照指数分布随机分配，模拟样本量的异构性；

(3) 双偏斜场景：同时叠加上述标签分布偏斜与样本量偏斜设置，模拟真实物联网场景中的双偏斜异构环境。

所有场景均设置 20 轮全局通信，每轮本地训练 5 个 epoch，优化器、学习率等超参数保持完全一致，实验结果如图 3.1 所示。




图 3.1 不同场景下 FedAvg 算法的分类精度变化曲线

Fig. 3.1 Classification accuracy variation curve of FedAvg algorithm in different scenarios

3.1.1.2 结果分析与实验观察

从实验结果可以观察到：单一标签分布偏斜或单一样本量偏斜场景下，FedAvg 算法在 20 轮通信后，分类精度均可收敛至 90% 以上，能够初步学习到数据的核心特征；而在标签分布偏斜与样本量偏斜同时存在的场景下，模型收敛速度明显变慢，20 轮通信后的分类精度低于 80%，与单一偏斜场景相比出现更明显的性能下降。

观察 1 在本文预实验设置下，双偏斜非 IID 数据对 FedAvg 全局模型的收敛速度和最终精度均产生更明显的负面影响，说明仅针对单一偏斜类型进行优化，难以充分覆盖真实物联网边缘场景中的数据异构问题。

3.1.2 客户端差异度与约束效应的关联验证

为了进一步分析双偏斜场景下模型性能衰减的原因，并为后续方法设计提供依据，本节从维度坍塌和客户端配对约束两个角度进行实验观察：一方面分析非 IID 数据对模型特征表示空间的影响，另一方面验证客户端间数据分布差异与配对约束效果之间的关系。

3.1.2.1 维度坍塌的现象分析

在联邦学习训练过程中，不同客户端的数据分布差异会导致本地优化目标偏离全局优化目标，进而使模型特征表示空间出现退化。设本地模型特征提取层的权重矩阵为 $W \in \mathbb{R}^{d \times m}$ ，对其进行奇异值分解可得 $W = U\Sigma V^T$ ，其中 $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_k)$ 为奇

异值对角矩阵。当大量奇异值快速衰减时，模型有效表示维度下降，特征空间难以充分区分不同类别的数据，最终影响分类精度。

观察 2 从维度坍塌视角看，若能够在本地训练阶段引入适当的客户端间约束，降低不同客户端模型更新方向的无序发散，有助于缓解非 IID 场景下的特征表示退化现象。该观察为本文后续设计配对正则化项提供了方法动机。

3.1.2.2 客户端差异度与约束效应的对照实验

基于上述分析，本节进一步验证客户端之间是否存在可利用的配对约束效应，以及该效应是否与客户端数据分布差异有关。实验设置 10 个客户端，采用 Dirichlet 分布 $\alpha = 0.01$ 模拟强异构场景，将客户端分为三组：高分布差异配对组、低分布差异配对组、未配对组，对比三组场景下模型特征层奇异值的分布情况。奇异值衰减速度越慢，说明特征表示空间退化越轻，模型保留的有效表示维度越高。实验结果如图3.2所示。




图 3.2 不同配对场景下模型奇异值的对数分布曲线

Fig. 3.2 Logarithmic distribution curves of model singular values in different pairing scenarios

3.1.2.3 结果分析与方法启示

从实验结果可以观察到：未配对组的奇异值衰减速度最快，维度坍塌现象更明显；低差异配对组的奇异值衰减速度略有放缓；高差异配对组的奇异值衰减速度相对更慢，与独立同分布基准场景的曲线更为接近，说明高差异度客户端之间的配对约束对缓解特征表示退化具有更明显的作用^[50]。

观察 3 在本文实验设置下，客户端间数据分布差异度越高，配对约束对奇异值衰减的缓解效果越明显。该现象说明，高差异度客户端配对可以作为非 IID 场景下构造互约束关系的一种可行策略。

基于上述观察，本文采用高差异度客户端配对作为方法设计依据，并在本地训练目标中引入配对正则化项。经典 FedAvg 算法中，客户端 i 的本地优化目标为：

$$\min_w \ell(w, X_i, y_i) \quad (3.1)$$

其中 $\ell(\cdot)$ 为本地任务损失函数， X_i, y_i 为客户端 i 的本地数据集。在双偏斜非 IID 场景下，该目标容易使客户端模型朝各自本地数据分布的方向优化，导致本地更新方向与全局优化方向出现偏离。

为缓解上述问题，本文引入基于配对客户端权重的正则化项，重构后的本地优化目标为：

$$\min_w \ell(w, X_i, y_i) + \beta \cdot \|w_i - w_j^{t-1}\|_2^2 \quad (3.2)$$

其中 w_i 为当前客户端 i 本轮训练的模型权重， w_j^{t-1} 为配对客户端 j 上一轮训练后的模型权重， β 为正则化系数，用于平衡主任务损失与配对约束项的权重。对上述目标求导，可得客户端 i 的本地训练梯度为：

$$\nabla \ell(w_i, X_i, y_i) + 2\beta \cdot (w_i - w_j^{t-1}) \quad (3.3)$$

新增的正则化梯度项会惩罚当前客户端权重与配对客户端权重的差异，从而约束本地更新不要过度偏离配对客户端的更新方向。该设计并不要求客户端交换原始数据，仅利用上一轮模型权重构造轻量级约束，适合与现有联邦学习训练流程结合。

3.1.3 核心问题形式化定义

基于上述实验观察与方法动机，本文针对物联网双偏斜非 IID 场景，对联邦学习的核心优化问题进行形式化定义。

设横向联邦学习系统共有 n 个客户端，每个客户端 i 持有本地数据集 D_i ，样本量为 $|D_i|$ ，全系统总样本量为 $|D| = \sum_{i=1}^n |D_i|$ 。在双偏斜非 IID 场景下，不同客户端的数据集同时存在标签分布偏斜与样本量偏斜，即：

- (1) 标签分布偏斜：客户端 i 与客户端 j 的标签分布 Q_i 与 Q_j 存在显著差异；
- (2) 样本量偏斜：客户端 i 与客户端 j 的样本量 $|D_i|$ 与 $|D_j|$ 存在数量级差异。

联邦学习的全局优化目标，是学习一个全局模型 M ，其参数为 θ ，最小化全局模型在所有客户端数据集上的加权经验损失，数学表达式为：

$$\min_{\theta} \mathcal{L}(\theta) = \sum_{i=1}^n \frac{|D_i|}{|D|} \mathcal{L}_i(\theta) \quad (3.4)$$

其中， $\mathcal{L}_i(\theta)$ 为模型参数 θ 在客户端 i 本地数据集上的损失函数，权重系数 $\frac{|D_i|}{|D|}$ 为客户端样本量占总样本量的比例。

本文的核心研究问题可形式化定义为：在双偏斜非 IID 场景下，设计一套轻量级、高兼容性的优化框架，在不修改联邦学习核心聚合流程、不引入显著计算开销的前提下，通过精准量化客户端间的双偏斜异构性，利用高差异度客户端的互约束效应，对齐不同客户端的梯度更新方向，缓解维度坍塌现象，最终实现全局模型在双偏斜非 IID 场景下的性能提升。

3.2 双偏斜异构性统一量化指标 JSDN 设计

基于 3.1 节的实验观察，要利用高差异度客户端的配对约束效应，首先需要解决的核心问题是：如何统一量化客户端之间的双偏斜异构性。现有研究大多仅采用单一指标量化标签分布差异，无法同时覆盖标签分布偏斜与样本量偏斜，难以完整表征双偏斜场景的异构程度。针对这一问题，本节设计了詹森-香农散度与偏斜指示数 (Jensen-Shannon Divergence and Skew Indicator Number, JSDN) 统一量化指标，用于同时刻画标签分布偏斜与样本量偏斜。

3.2.1 标签分布偏斜量化方法

针对标签分布偏斜的量化，本文采用詹森-香农散度^[51] (Jensen-Shannon Divergence, JSD) 作为基础量化指标。JSD 是在库尔贝克-莱布勒散度 (Kullback-Leibler Divergence, KLD) 基础上改进的分布相似度量指标，解决了 KLD 不对称、无界的缺陷，其取值范围固定在 $[0,1]$ 区间内，能够稳定、对称地量化两个概率分布之间的差异程度，适用于联邦学习客户端标签分布的量化场景。

对于两个客户端 a 与 b ，其标签分布分别为 Q_a 与 Q_b ，JSD 的数学定义为：

$$\mathcal{JSD}(Q_a, Q_b) = \frac{1}{2} \sum_{i \in \{a, b\}} \mathcal{KL}(Q_i, \mathbb{M}_{ab}) \quad (3.5)$$

其中， $\mathcal{KL}(\cdot)$ 为 KLD 散度^[52]，用于量化两个概率分布的相对熵； $\mathbb{M}_{ab}$ 为两个标签分布的均值分布，计算公式为：

$$\mathbb{M}_{ab} = \frac{Q_a + Q_b}{2} \quad (3.6)$$

JSD 指标的物理意义与核心特性如下：

- (1) 取值范围固定在 $[0, 1]$ 区间内，JSD 值越大，代表两个客户端的标签分布差异越大，标签分布偏斜程度越严重；
- (2) 具备对称性，即 $\mathcal{JSD}(Q_a, Q_b) = \mathcal{JSD}(Q_b, Q_a)$ ，不受客户端顺序的影响，适配客户端配对的场景需求；
- (3) 当且仅当两个客户端的标签分布完全一致时，JSD 值为 0，符合分布相似度量化的基本逻辑。

3.2.2 样本量偏斜量化方法

针对样本量偏斜的量化，本文设计了归一化的样本量偏斜指示数 N ，用于量化两个客户端之间的样本量差异程度。为了与 JSD 指标的取值范围保持一致，实现后续的加权融合，本文将样本量差异映射到 $[0, 1]$ 区间内，计算公式为：

$$N = \frac{|N_a - N_b|}{N_a + N_b} \quad (3.7)$$

其中， N_a 与 N_b 分别为客户端 a 与客户端 b 的本地数据集样本量。

样本量偏斜指示数 N 的物理意义与核心特性如下：

- (1) 取值范围固定在 $[0, 1]$ 区间内， N 值越大，代表两个客户端的样本量差异越大，样本量偏斜程度越严重；
- (2) 具备对称性，不受客户端顺序的影响，与 JSD 指标的特性保持一致；
- (3) 当且仅当两个客户端的样本量完全相等时， N 值为 0，符合样本量差异量化的基本逻辑。

3.2.3 JSDN 融合指标设计与特性分析

基于上述标签分布偏斜量化指标 JSD 与样本量偏斜量化指标 N ，本文通过加权融合的方式，设计了双偏斜异构性统一量化指标 $JSDN$ ，计算公式为：

$$JSDN = (1 - \lambda)JSD + \lambda N \quad (3.8)$$

其中， λ 为权重参数，取值范围为 $[0,1]$ ，用于平衡标签分布偏斜与样本量偏斜在整体异构性量化中的权重占比。

$JSDN$ 指标的核心特性与设计优势如下：（1）双维度统一量化：将标签分布偏斜与样本量偏斜纳入统一的量化框架，能够表征双偏斜场景的异构程度，缓解单一指标难以覆盖双偏斜场景的问题；

（2）灵活的权重适配：通过调整权重参数 λ ，可适配不同场景下两种偏斜的影响程度。例如在标签分布差异主导的场景中，可降低 λ 的取值；在样本量差异主导的场景中，可提高 λ 的取值；

（3）稳定的取值特性： $JSDN$ 指标的取值范围固定在 $[0,1]$ 区间内，值越大代表两个客户端之间的双偏斜异构程度越高，数据分布差异越大，可为后续客户端配对提供量化依据。

3.3 基于 JSDN 的客户端配对算法设计

基于 $JSDN$ 双偏斜异构性统一量化指标，本节设计了最大化分布差异的客户端配对算法，核心目标是优先将数据分布差异较大的客户端进行配对，以增强配对约束的作用。同时，本节结合本地差分隐私机制，降低客户端标签分布与样本量信息上传过程中的隐私泄露风险。

3.3.1 基于 LDP 的隐私保护数据上传机制

客户端配对的前提，是服务器获取各客户端的标签分布与样本量信息，用于计算 $JSDN$ 矩阵。但直接上传原始标签分布与样本量，可能泄露客户端的本地数据隐私，违背联邦学习的隐私保护核心原则。因此，本文采用本地差分隐私（Local Differential Privacy, LDP）机制，在客户端本地对需要上传的信息进行噪声扰动后，再上传至服务器，全程不泄露原始数据信息。

LDP 扰动的完整流程如下：

(1) 对于客户端 k 的标签分布向量 h_k ，添加服从拉普拉斯分布的噪声，扰动后的标签分布为：

$$\tilde{h}_k = h_k + (Lap(2/\epsilon_h))^C \quad (3.9)$$

其中， C 为分类任务的类别总数， ϵ_h 为标签分布的隐私预算，拉普拉斯噪声的尺度由标签分布的 ℓ_1 -灵敏度 ($\Delta_1 h_k = 2$) 决定。

(2) 对于客户端 k 的样本量 N_k ，添加服从拉普拉斯分布的噪声，扰动后的样本量为：

$$\tilde{N}_k = N_k + Lap(1/\epsilon_N) \quad (3.10)$$

其中， ϵ_N 为样本量的隐私预算，拉普拉斯噪声的尺度由样本量的 ℓ_1 -灵敏度 ($\Delta_1 N_k = 1$) 决定。

(3) 为了平衡隐私保护强度与数据效用，采用最优隐私预算分配策略，总隐私预算 $\epsilon = \epsilon_h + \epsilon_N$ ，最优分配公式为：

$$\epsilon_h^* = \epsilon \cdot \frac{\sqrt{C/N_k}}{\sqrt{C/N_k} + 1}, \quad \epsilon_N^* = \epsilon - \epsilon_h^* \quad (3.11)$$

客户端完成上述扰动后，仅将扰动后的标签分布 $\tilde{h}_k$ 与样本量 $\tilde{N}_k$ 上传至服务器。服务器基于扰动后的数据计算 JSDN 矩阵，无需获取客户端的原始数据信息，从而降低标签分布和样本量信息上传带来的隐私泄露风险。

3.3.2 JSDN 矩阵构建与配对算法实现

服务器接收到所有客户端扰动后的标签分布与样本量后，首先构建 JSDN 矩阵，再通过迭代寻优的方式完成客户端配对，核心逻辑是优先配对 JSDN 值最大的客户端对，最大化利用高差异度客户端的互约束效应。

算法的完整执行流程如下：

(1) JSDN 矩阵初始化：设参与训练的客户端总数为 n ，初始化一个 $n \times n$ 的全零矩阵 J ；

(2) 矩阵填充：遍历所有客户端对 (i, j) ($i < j$)，基于客户端 i 与 j 的扰动后标签分布与样本量，计算 JSDN 值 J_{ij} ，并赋值 $J_{ji} = J_{ij}$ ，保证矩阵的对称性；

(3) 迭代配对：循环执行以下步骤，直至所有可配对客户端完成配对：遍历 JSDN 矩阵，找到矩阵中的最大值 J_{max} ，对应的客户端编号为 i^* 与 j^* ，将该客户端对加入配对集合；将矩阵中第 i^* 行、第 j^* 行、第 i^* 列、第 j^* 列的所有元素置零，避免已配对客户端重复参与配对；

(4) 输出结果：返回最终的客户端配对集合。

3.3.3 客户端数量奇偶性适配方案

在真实物联网场景中，参与训练的客户端总数可能为奇数，无法完成全量两两配对，针对这一问题，本文设计了轻量化的适配方案：当客户端总数 n 为奇数时，完成 $(n-1)/2$ 组客户端配对后，剩余 1 个未配对的客户端，直接舍弃该客户端本轮的配对资格，不参与本轮的配对约束训练，细节见算法1。

该方案的设计逻辑如下：剩余未配对客户端通常对应当前轮次中未被高 JSDN 值优先选中的客户端，其与其他客户端配对所带来的约束收益相对有限。跳过该客户端本轮的配对约束，不影响其参与常规本地训练和全局聚合，同时可以简化配对算法对奇数客户端场景的处理。

3.4 FCPC 基础框架与配对约束机制设计

本章前序章节已完成双偏斜异构性的统一量化与高差异度客户端配对。为将客户端间的配对约束嵌入联邦训练流程，并降低不同客户端本地更新方向的偏离，本节构建联邦客户端配对与互约束（Federated Client Pairing and Mutual Constraint, FCPC）基础框架。框架核心设计遵循轻量化、即插即用原则，仅在本地训练阶段引入正则化约束，无需修改联邦学习的核心聚合逻辑与模型架构。

3.4.1 配对正则化项设计与优化目标构建

基于 3.1 节的实验观察，高差异度客户端之间的配对约束有助于降低本地模型更新方向的差异。为了将该约束嵌入本地训练流程，本文设计了基于配对客户端权重的轻量级正则化项，数学表达式为：

$$L_{FCPC}(w_k, X) = \|w_k^t - w_{k'}^{t-1}\|^2 \quad (3.12)$$

算法 1: 客户端配对算法

```

1 Input: LDP 扰动后的客户端标签分布集合  $\hat{p} = \{\hat{p}_1, \dots, \hat{p}_n\}$ 
2 LDP 扰动后的客户端样本量集合  $\hat{N} = \{\hat{N}_1, \dots, \hat{N}_n\}$ 
3 客户端总数  $n$ 
4 Output: 客户端配对集合  $P_{pairs}$ 
5 初始化 JSDN 矩阵  $J \leftarrow \text{zeros}(n \times n)$ ;
6 for  $i \leftarrow 1$  to  $n$  do
7     for  $j \leftarrow i + 1$  to  $n$  do
8         | 计算客户端  $i$  与  $j$  的 JSDN 值  $J_{ij} = J_{ji} = \text{JSDN}(\hat{p}_i, \hat{p}_j; \hat{N}_i, \hat{N}_j)$ ;
9     end
10 end
11 初始化配对集合  $P_{pairs} \leftarrow \emptyset$ ;
12 if  $n$  为偶数 then
13     for  $k \leftarrow 1$  to  $n/2$  do
14         |  $(i^*, j^*) \leftarrow \arg \max J_{ij}$ ;
15         |  $P_{pairs} \cup = \{(i^*, j^*)\}$ ;
16         | for  $x \leftarrow 1$  to  $n$  do
17             |  $J_{i^*x} \leftarrow 0, J_{j^*x} \leftarrow 0, J_{xi^*} \leftarrow 0, J_{xj^*} \leftarrow 0$ ;
18         | end
19     end
20 else
21     for  $k \leftarrow 1$  to  $(n-1)/2$  do
22         |  $(i^*, j^*) \leftarrow \arg \max J_{ij}$ ;
23         |  $P_{pairs} \cup = \{(i^*, j^*)\}$ ;
24         | for  $x \leftarrow 1$  to  $n$  do
25             |  $J_{i^*x} \leftarrow 0, J_{j^*x} \leftarrow 0, J_{xi^*} \leftarrow 0, J_{xj^*} \leftarrow 0$ ;
26         | end
27     end
28 end
29 return  $P_{pairs}$ ;
    
```

其中, w_k^t 为第 t 轮通信中, 客户端 k 本地训练过程中的模型权重; $w_{k'}^{t-1}$ 为第 $t-1$ 轮通信中, 与客户端 k 配对的客户端 k' 完成本地训练后的最终模型权重。

该正则化项通过欧氏距离惩罚当前轮本地客户端权重与上一轮配对客户端权重的差异, 引导本地更新不要过度偏离配对客户端的历史更新方向。该设计无需客户端之间交互原始数据, 但若采用完整模型权重作为配对锚点, 仍会产生一定的模型级通信开销; 该开销可通过服务器缓存、低频锚点更新或仅约束部分模型参数等方式进一步降低。

基于上述正则化项，客户端本地训练的整体优化目标为：

$$\min_w \ell(w, X, y) + \beta L_{FCPC}(w, X) \quad (3.13)$$

其中， $\ell(w, X, y)$ 为本地训练的主任务损失函数（本文采用分类任务标准交叉熵损失）， β 为 FCPC 正则化系数，用于平衡主任务损失与配对约束项的权重占比，控制约束效应的强度。

3.4.2 FCPC 完整训练流程与系统架构

FCPC 框架的完整系统架构如图3.3所示，整体分为两大核心流程：一是基于 LDP 的隐私保护客户端配对流程，二是基于配对约束的联邦协同训练流程，两大流程相互独立又协同配合，全程不修改 FedAvg 的核心聚合逻辑，保证了框架的即插即用特性。




图 3.3 FCPC 框架

Fig. 3.3 FCPC framework

FCPC 框架的完整训练流程分为 6 个核心步骤，与架构图一一对应：

(1) 全局模型初始化与分发：中心服务器完成全局模型的参数初始化，将初始模型权重分发至所有参与训练的客户端；

(2) 隐私保护数据上传：各客户端在本地完成标签分布与样本量的 LDP 噪声扰动，仅将扰动后的信息上传至中心服务器，全程不泄露原始数据；

(3) JSDN 矩阵计算与配对序列生成：服务器基于客户端上传的扰动信息，计算 JSDN 矩阵，通过 3.3 节的配对算法完成客户端配对，将配对序列下发至对应客户端；

(4) 带约束的本地训练：各客户端基于本地数据集，按照式 (3.13) 的优化目标完成本地训练，配对客户端之间仅传输上一轮的模型权重，用于构建正则化约束项；

(5) 本地模型更新上传：完成本地训练后，各客户端将本地模型权重上传至中心服务器，用于全局聚合；

(6) 全局模型聚合与更新：服务器采用标准 FedAvg 加权平均策略完成全局模型聚合，将更新后的全局模型分发至所有客户端，进入下一轮通信迭代，直至模型收敛或达到预设最大通信轮次。

FCPC 框架的完整训练算法伪代码如算法2所示。

算法 2: FCPC 完整训练算法

```

1 Input: 每轮参与训练的客户端数  $K$ , 总通信轮次  $T$ , 正则化系数  $\beta$ , 初始模型权重  $w_0$ , 客户端总数  $n$ , 客户端样本量权重  $p_k$  ( $k = 1, \dots, n$ )
2 Output: 训练完成的全局模型  $w_T$ 
3 初始化全局模型权重  $w_0$ , 空的客户端参与集合  $S_t$ ;
4 for  $t \leftarrow 0$  to  $T - 1$  do
5      $S_t \leftarrow$  随机选取  $K$  个客户端构成参与集合;
6     向所有  $k \in S_t$  分发当前全局模型  $w_t$ ;
7     for each  $k \in S_t$  in parallel do
8          $w_k^{t+1} \approx \arg \min_w \ell(w; X, y) + \beta \|w_k^t - w_k^{t-1}\|^2$ ;
9     end
10    for each  $k \in S_t$  do
11        客户端  $k$  向服务器上传本地训练完成的权重  $w_k^{t+1}$ ;
12    end
13     $w_{t+1} \leftarrow \frac{1}{|S_t|} \sum_{k \in S_t} w_k^{t+1}$ ;
14 end
15 return 最终优化全局模型  $w_T$ ;
    
```

3.5 基础框架收敛性理论分析

本节对 FCPC 框架的收敛性进行理论分析，给出框架收敛所需的前提假设、核心引理和误差上界。

3.5.1 收敛性分析前提假设

为保证理论分析的严谨性，本文采用联邦学习收敛性分析通用的标准假设，所有假设均符合真实训练场景的客观规律：

假设 1 (Lipschitz 连续) 所有客户端的本地损失函数 $\mathcal{L}_i(w)$ 均为 L -Lipschitz 连

续^[53, 54], 即对于任意权重 w_1, w_2 , 满足:

$$\|\nabla \mathcal{L}_i(w_1) - \nabla \mathcal{L}_i(w_2)\| \leq L\|w_1 - w_2\| \quad (3.14)$$

假设 2 (强凸性) 所有客户端的本地损失函数 $\mathcal{L}_i(w)$ 均为 μ -强凸函数, 即对于任意权重 w_1, w_2 , 满足:

$$\mathcal{L}_i(w_1) \geq \mathcal{L}_i(w_2) + \nabla \mathcal{L}_i(w_2)^T(w_1 - w_2) + \frac{\mu}{2}\|w_1 - w_2\|^2 \quad (3.15)$$

假设 3 (梯度有界性) 所有客户端的本地损失函数梯度均有上界, 即存在常数 G , 对于任意权重 w , 满足 $\|\nabla \mathcal{L}_i(w)\| \leq G$ 。

假设 4 (客户端数据分布) 客户端的本地数据分布满足有界差异, 即存在常数 Γ , 任意客户端的本地损失函数梯度与全局损失函数梯度的差异满足 $\|\nabla \mathcal{L}_i(w) - \nabla \mathcal{L}(w)\| \leq \Gamma$ 。

3.5.2 核心引理与收敛性定理

基于上述假设, 首先给出两个核心引理, 为最终的收敛性定理提供支撑:

引理 1 对于 FCPC 框架的本地更新规则, 任意客户端 k 的本地权重更新满足:

$$\|w_k^{t+1} - w^*\|^2 \leq (1 - \mu\eta)\|w_k^t - w^*\|^2 + 2\eta\beta\|w_k^t - w_{k'}^{t-1}\| \cdot \|w_k^{t+1} - w^*\| + \eta^2 L^2 G^2 \quad (3.16)$$

其中, w^* 为全局损失函数的最优解, η 为学习率。该引理刻画了本地权重更新与全局最优解之间的误差上界, 明确了配对约束项对误差的影响。

引理 2 对于配对客户端 k 与 k' , 二者的权重差异满足有界性:

$$\|w_k^t - w_{k'}^{t-1}\| \leq \frac{2G}{\mu} + \Gamma T \quad (3.17)$$

该引理证明了配对客户端的权重差异存在固定上界, 不会随着训练轮次的增加而发散, 保证了正则化项的稳定性。

基于上述两个引理, 本文给出 FCPC 框架的核心收敛性定理:

定理 1 在假设 1-4 的条件下, 当学习率 η 满足 $\eta \leq \frac{1}{L}$, 正则化系数 β 满足 $\beta \leq \frac{\mu}{4}$ 时,

经过 T 轮通信迭代后, FCPC 框架的全局模型权重与最优解的误差满足:

$$\mathbb{E}[\|\bar{w}^T - w^*\|^2] \leq (1 - \frac{\mu\eta}{2})^T \|\bar{w}^0 - w^*\|^2 + \frac{8\eta^2 L^2 G^2 + 32\beta^2 (\frac{2G}{\mu} + \Gamma T)^2}{\mu^2 \eta T} \quad (3.18)$$

其中, $\bar{w}^T$ 为第 T 轮的全局模型权重。

该定理表明: 在上述标准假设下, FCPC 框架的全局模型误差可被控制在给定上界内。上界中包含与正则化系数 β 相关的项, 因此在实际训练中需要结合消融实验选择合适的 β , 以平衡本地任务学习与配对约束强度。

3.6 基础框架核心性能实验验证

为验证 FCPC 基础框架在单/双偏斜非 IID 场景下的有效性, 本节基于标准数据集完成对照实验。

3.6.1 实验环境与基础参数设置

所有实验均采用统一的软硬件环境与超参数设置, 保证对照实验的公平性:

- 模型架构: 图像分类任务采用 ResNet18^[55] 与 MobileNetV2^[56], 适配物联网边缘设备的轻量化部署需求;
- 训练超参数: 所有实验设置 100 轮全局通信, 每轮通信中客户端本地训练 10 个 epoch, 采用 SGD 优化器^[57], 初始学习率 0.01, batch size 为 64, 所有实验均采用相同的数据增强策略^[58];
- 非 IID 场景模拟: 采用 Dirichlet 分布模拟标签分布偏斜, 分布参数 $\alpha \in \{0.05, 0.1, 0.5\}$, 数值越小代表异构性越强; 样本量偏斜采用指数分布随机分配客户端样本量^[59];
- 数据集: 采用 5 个联邦学习领域标准数据集, 包括手写数字数据集 MNIST^[60]、手写字符数据集 FEMNIST、图像分类数据集 CIFAR-10^[61]、CIFAR-100、TinyImageNet;
- 对比基线: 选取 5 种主流非 IID 联邦学习算法作为对比基线, 包括 FedAvg、FedProx、MOON、FedDyn、FBLG、FedCFA, 所有基线算法的超参数均参考相关论文中的推荐设置。

3.6.2 单类型非 IID 场景性能验证

首先验证 FCPC 框架在单一标签分布偏斜、单一样本量偏斜场景下的性能表现，为直观展示 FCPC 框架在单偏斜场景下的性能优势，图3.4 给出了 MNIST 与 FEMNIST 数据集上各算法的对比结果。可以看出，FCPC 在两类偏斜场景中均取得最高精度，具体数值见表3.1。




图 3.4 单类型非 IID 场景下基于 MNIST 系列数据集算法精度

Fig. 3.4 Accuracy of algorithms based on MNIST series dataset in single type Non-IID scenarios

从实验结果可以看出：在两类单偏斜场景下，FCPC 框架的分类精度均显著优于所有对比基线。在 MNIST 标签偏斜场景下，FCPC 较基准 FedAvg 提升 0.83 个百分点；在 FEMNIST 样本量偏斜场景下，FCPC 较 FedAvg 提升 1.27 个百分点。该结果验证了：FCPC 框架的配对约束机制，能够有效缓解单一类型非 IID 异构性带来的性能衰减，具备良好的场景适配性。

表 3.1 单类型非 IID 场景下 MNIST 与 FEMNIST 数据集的测试精度

Tab. 3.1 Test accuracy of MNIST and FEMNIST datasets under single-type non-IID scenarios

非 IID 场景	数据集	FCPC	FedAvg	FedProx	FedDyn	MOON
标签分布偏斜	MNIST	98.15%	97.32%	97.96%	97.48%	97.54%
	FEMNIST	97.34%	96.35%	96.28%	97.09%	96.56%
样本量偏斜	MNIST	98.28%	97.18%	97.78%	97.63%	97.65%
	FEMNIST	97.24%	95.97%	96.37%	96.52%	96.36%

3.6.3 双偏斜非 IID 场景性能验证

为验证 FCPC 框架在核心研究场景（标签 + 样本量双偏斜）下的性能表现，本节先采用 CIFAR 系列数据集，设置 3 种不同异构程度的双偏斜场景。图3.5 进一步展示了双偏斜场景下 CIFAR-10 与 CIFAR-100 的性能对比。随着异构程度增加（ α 减小），FCPC 的优势愈发显著，在极端异构场景（ $\alpha=0.05$ ）下较基准算法提升明显，详细数据见表3.2。




图 3.5 双偏斜非 IID 场景下基于 CIFAR 系列数据集算法精度

Fig. 3.5 Accuracy of algorithms based on CIFAR series dataset in dual skewed Non-IID scenarios

实验结果表明：在所有异构程度的双偏斜场景下，FCPC 框架均取得了较优的分类精度，且异构性越强，性能优势越明显。在极端异构场景（ $\alpha = 0.05$ ）下，FCPC 在 CIFAR-10 数据集上取得 63.17% 的 Top-1 精度，较基准 FedAvg 提升 9.4 个百分点，较 FedCFA 略有提升。

表 3.2 不同异构程度双偏斜场景下 CIFAR-10 数据集的性能对比

Tab. 3.2 Performance comparison of CIFAR-10 dataset under double-skew non-IID scenarios with different heterogeneity degrees

方法	$\alpha = 0.05$	$\alpha = 0.1$	$\alpha = 0.5$
FedAvg	53.74%	65.19%	79.98%
FedProx	53.21%	65.20%	79.46%
MOON	59.68%	67.60%	80.04%
FedDyn	62.24%	68.49%	77.38%
FBLG	62.95%	69.13%	79.82%
FedCFA	63.15%	69.83%	80.45%
FCPC	63.17%	70.59%	80.28%

为了验证了所提方法的泛化能力与鲁棒性，选择了更复杂、类别更多的 CIFAR-100

数据集上进行进一步实验。FCPC 同样展现出稳定且一致的性能增益，如表3.3所示：FCPC 较 FedAvg 提升 2.77 个百分点，优于所有对比基线。该结果充分验证了：JSDN 双偏斜统一量化指标与高差异度配对约束机制，能够有效缓解双偏斜异构性带来的梯度发散与维度坍塌，在核心研究场景下具备显著的性能优势。

表 3.3 不同异构程度双偏斜场景下 CIFAR-100 数据集的性能对比

Tab. 3.3 Performance comparison of CIFAR-100 dataset under double-skew non-IID scenarios with different heterogeneity degrees

方法	$\alpha = 0.05$	$\alpha = 0.1$	$\alpha = 0.5$
FedAvg	49.76%	56.43%	61.40%
FedProx	50.22%	56.37%	61.59%
MOON	45.68%	56.37%	61.81%
FedDyn	49.73%	56.36%	61.28%
FBLG	50.45%	57.62%	61.38%
FedCFA	51.47%	57.81%	62.13%
FCPC	52.53%	58.12%	62.72%

3.7 本章小结

本章作为本文的第一研究工作，围绕物联网双偏斜非 IID 场景下的异构性量化与模型优化问题展开研究。首先通过预实验分析了双偏斜数据对 FedAvg 收敛性能的影响，并从维度坍塌角度讨论了客户端配对约束的设计动机；其次设计了 JSDN 双偏斜异构性统一量化指标，用于同时刻画标签分布偏斜与样本量偏斜；随后基于 JSDN 指标设计了最大化分布差异的客户端配对算法，并结合配对正则化项构建了 FCPC 基础框架；最后通过收敛性分析和多数据集对照实验，验证了框架在单/双偏斜非 IID 场景下的有效性。本章的基础框架设计与核心性能验证，为下一章的正交性验证、鲁棒性分析与物联网场景落地优化奠定了基础。

第四章 框架的正交性优化与 IoT 场景落地

本章为本文的第二研究工作，核心目标是进一步验证第一研究工作提出的 FCPC 基础框架在物联网场景中的兼容性、鲁棒性与部署开销，为后续场景化应用提供实验依据和可行性分析。

4.1 研究动机与优化目标

本文第 3 章的第一研究工作，已完成 FCPC 基础框架的设计与核心性能验证，通过多数据集对照实验证明：FCPC 框架能够有效缓解双偏斜非 IID 场景下的联邦学习模型性能衰减问题，在极端异构场景下取得了较好的分类精度。但从工程落地的视角来看，基础框架的核心性能验证主要集中于方法有效性，要进一步支撑其在物联网场景中的应用，还需补充三个方面的分析，这也是本章的核心研究动机：

第一，工程落地的兼容性验证。现有非 IID 联邦学习优化方案，部分需要修改联邦学习的核心聚合逻辑、模型架构或训练流程，与 FATE、FedML 等联邦学习框架的兼容性存在一定限制，落地部署时往往需要对现有系统进行改造^[39]。FCPC 框架在设计上遵循即插即用的原则，但其与现有主流联邦学习算法的正交兼容性，还需通过系统实验进行验证，这是其工程应用的重要前提。

第二，核心模块的有效性拆解验证。FCPC 框架的性能提升，来自 JSDN 双偏斜量化指标、客户端配对算法、配对正则化约束三大核心模块的协同作用。现有实验主要验证了完整框架的整体性能，仍需对各模块的独立贡献、核心超参数的影响规律进行拆解分析，从而解释框架性能提升的内在机理，并为场景化应用中的超参数调优提供依据。

第三，复杂场景的鲁棒性与开销分析。物联网场景的异构程度、设备规模、环境条件具有较强不确定性，需要验证框架在极端异构场景、不同超参数配置下的稳定性与鲁棒性，并进一步分析其通信开销、计算复杂度和边缘资源占用，明确框架的适用边界与部署成本。

基于上述工程落地的核心需求，本章的核心优化目标与研究内容规划如下：

(1) 完成 FCPC 框架与主流联邦学习算法的正交性验证，通过多数据集、多异构度、多基线算法的对照实验，系统验证框架的即插即用特性，说明其在不修改原有算法核心

架构的条件下，仍能够带来稳定的性能提升；

(2) 通过多组消融实验，拆解 FCPC 框架核心模块的有效性，分析关键超参数对模型性能的影响规律，明确全场景适配的最优超参数取值，为落地部署提供调优依据；

(3) 基于实验结果分析 FCPC 框架在极端异构场景下的鲁棒性，并补充通信开销、计算复杂度与边缘资源占用分析，结合智能交通 IoT 场景给出部署设计与多规模模型开销分析。

本章的研究内容与第一研究工作形成递进关系：第一工作重点解决“双偏斜场景下模型性能提升”的方法设计问题；本章进一步围绕“框架能否兼容主流算法、核心模块是否有效、部署开销是否可控、如何面向 IoT 场景应用”等问题展开分析，共同构成“方法设计-性能验证-开销分析-场景适配”的研究体系。

4.2 FCPC 框架与主流 FL 算法的正交性验证

4.2.1 正交性设计原理与融合方案

本文提出的 FCPC 框架，核心设计优势之一是与现有联邦学习算法的正交性，即框架的核心模块与现有联邦学习算法的核心逻辑相对解耦，不改变原有算法的模型架构、聚合流程和本地训练主流程，仅需在训练前增加客户端配对模块，并在本地损失函数中加入配对正则化项，即可完成与现有算法的集成。

在训练启动前，复用本文提出的 LDP 隐私保护上传、JSDN 矩阵计算、客户端配对流程，为每个客户端确定配对对象，该流程与原有算法的训练逻辑完全独立；在客户端本地训练阶段，在原有算法的损失函数中，加入本文提出的 FCPC 配对正则化项，无需修改原有算法的损失函数主体、优化器、本地迭代逻辑，也无需修改服务器端的全局聚合策略。

这种正交性设计能够降低物联网场景中的系统改造成本：在已有联邦学习系统中，仅需增加轻量化的配对模块与正则化项，即可在保持原有聚合逻辑的基础上提升模型在非 IID 场景下的性能，具有较好的工程适配性。

为了系统验证 FCPC 框架的正交性与即插即用特性，本节选取 5 种具有代表性的联邦学习算法作为集成基线，包括经典基准算法 FedAvg、正则化类算法 FedProx^[13]、对比学习类算法 MOON^[14]、双偏斜优化算法 FBLG^[17]、因果推理类算法 FedCFA^[16]，覆盖了

当前非 IID 联邦学习中的多类优化思路，具有较好的代表性。

4.2.2 实验设置

所有实验均与第 3 章的核心实验保持完全一致的环境配置，保证对照实验的公平性与可复现性：

- 数据集：选取 CIFAR-10 与 TinyImageNet 两个复杂度不同的图像分类数据集，覆盖从简单到复杂的分类任务场景；
- 非 IID 场景设置：采用 Dirichlet 分布模拟双偏斜非 IID 场景，分布参数 $\alpha \in \{0.05, 0.1, 0.5\}$ ，覆盖从极端异构到中度异构的全场景；
- 模型与训练超参数：采用 ResNet18 作为基准模型，训练轮次、学习率、优化器、batch size 等超参数均与第 3 章保持一致；
- 评估指标：采用分类任务的 Top-1 准确率作为核心评估指标，对比集成 FCPC 前后，各基线算法的性能变化。

4.2.3 实验结果与深度分析

FCPC 框架与 5 种主流基线算法融合的具体提升效果可见图4.1，其中 α 取值的由低到高，依次代表数据异构程度的逐渐减小。具体数据，在 CIFAR-10 数据集上的正交性验证结果如表4.1所示，在 TinyImageNet 数据集上的验证结果如表4.2所示。

表 4.1 CIFAR-10 数据集上 FCPC 与主流 FL 算法的正交性验证结果 (ResNet-18)
Tab. 4.1 Orthogonality verification results of FCPC and mainstream FL algorithms on CIFAR-10 dataset (ResNet-18)

异构度 α	FedAvg		FedProx		MOON		FBLG		FedCFA	
	原始	+FCPC	原始	+FCPC	原始	+FCPC	原始	+FCPC	原始	+FCPC
0.05	53.74%	63.17%	53.21%	61.29%	59.68%	63.46%	62.95%	63.08%	63.15%	64.23%
0.1	65.19%	70.59%	65.20%	72.83%	67.60%	72.26%	69.13%	70.45%	69.83%	72.29%
0.5	79.98%	80.28%	79.46%	80.35%	80.04%	80.82%	79.82%	80.83%	80.45%	81.62%

从 CIFAR-10 数据集的实验结果可以得到三个核心结论：第一，FCPC 框架对所有主流基线算法均能带来稳定的性能提升，且异构性越强，提升效果越显著。在极端异构场景 ($\alpha = 0.05$) 下，FCPC 为基准 FedAvg 带来了 9.43 个百分点的精度提升，为 FedProx 带来了 8.08 个百分点的提升；对于针对非 IID 场景优化的 FedCFA，集成 FCPC 后仍能获得 1.08 个百分点的精度提升，说明 FCPC 框架具有一定的普适性。第二，FCPC 框架

的性能提升不依赖于原有算法的优化逻辑，无论是最基础的 FedAvg，还是基于正则化、对比学习、因果推理的优化算法，集成 FCPC 后均能获得稳定的性能增益，说明框架与现有算法具备较好的正交兼容性。第三，在中度异构场景 ($\alpha = 0.5$) 下，FCPC 仍能为各基线算法带来 0.3%-1.17% 的精度提升，证明框架在全异构度场景下均具备有效性，不会出现异构度降低后性能失效的问题。




图 4.1 FCPC 框架与主流联邦学习算法的正交性

Fig. 4.1 The orthogonality between FCPC framework and mainstream federated learning algorithms

TinyImageNet 数据集的分类任务复杂度更高、类别更多，对非 IID 异构性更为敏感，实验结果进一步验证了 FCPC 框架的正交性与有效性：在极端异构场景 ($\alpha = 0.05$) 下，FCPC 为各基线算法带来了约 5 个百分点的稳定精度提升；在中度异构场景下，仍能带来 3.3%-3.5% 的性能增益。即使是在高复杂度分类任务中，FCPC 框架仍能通过配对约束机制，有效缓解非 IID 数据带来的性能衰减，且完全不依赖原有算法的核心逻辑，进一步证明了其在复杂物联网真实场景中的落地适配能力。

综合两组实验结果可以得出结论：FCPC 框架与现有主流联邦学习算法具备较好的正交兼容性，无需修改原有算法的核心架构与训练流程，即可实现稳定的性能提升，体现了即插即用的设计目标，对降低非 IID 优化方案的落地改造成本具有一定工程价值。

表 4.2 TinyImageNet 数据集上 FCPC 与主流 FL 算法的正交性验证结果

Tab. 4.2 Orthogonality verification results of FCPC and mainstream FL algorithms on TinyImageNet dataset

算法	$\alpha = 0.05$	$\alpha = 0.1$	$\alpha = 0.5$
FedAvg	35.48%	39.53%	46.97%
+FCPC	40.47%	44.36%	50.28%
FedProx	35.50%	39.69%	47.23%
+FCPC	40.68%	44.33%	50.53%
MOON	35.49%	40.81%	47.91%
+FCPC	40.64%	44.42%	51.32%
FedCFA	35.62%	40.94%	48.11%
+FCPC	40.71%	44.57%	51.48%

4.3 FCPC 框架核心模块消融实验与鲁棒性分析

为了拆解 FCPC 框架各核心模块的独立贡献，明确关键超参数对模型性能的影响规律，验证框架在复杂场景下的鲁棒性，本节设计多组消融实验，并在相同实验条件下对不同模块和超参数配置进行对照分析。

4.3.1 JSDN 权重参数 λ 的消融实验

JSDN 指标是 FCPC 框架的核心基础，其权重参数 λ 用于平衡标签分布偏斜 (JSD) 与样本量偏斜 (N) 在异构性量化中的权重占比，直接决定了客户端配对的准确性，进而影响框架的最终性能。为了明确 λ 的最优取值与影响规律，本节设计对照消融实验。

4.3.1.1 实验设置

选取 MNIST 与 FEMNIST 两个标准数据集，设置 Dirichlet 分布参数 $\alpha = 0.5$ 模拟中度异构场景，将 λ 的取值设置为 $\{0.1, 0.2, 0.3, 0.4\}$ ，固定其他所有超参数与实验环境不变，对比不同 λ 取值下模型的最终分类精度，实验结果如图4.2所示。

4.3.1.2 结果分析

从实验结果可以清晰观察到 λ 对模型性能的影响规律：

(1) 当 λ 从 0.1 提升至 0.3 时，两个数据集的模型分类精度均呈现持续上升趋势，说明在异构性量化中，适当增加样本量偏斜的权重，能够更全面地表征客户端之间的真实




图 4.2 λ 消融实验
Fig. 4.2 λ ablation experiment

异构程度，提升配对的准确性，进而优化模型性能；

(2) 当 $\lambda = 0.3$ 时，两个数据集的模型精度均达到峰值，此时 JSDN 指标能够最优化地平衡标签分布偏斜与样本量偏斜的影响，实现最精准的异构性量化；

(3) 当 λ 从 0.3 继续提升至 0.4 时，模型精度出现明显下降，说明过度强调样本量偏斜的权重，会弱化标签分布偏斜的核心影响，导致配对准确性下降，反而影响模型的最终性能。

综合实验结果，本文选取 $\lambda = 0.3$ 作为全场景适配的最优默认值，该取值能够在不同数据集、不同异构程度的场景下，实现标签与样本量偏斜的最优平衡，保证 JSDN 指标的量化准确性。

4.3.2 正则化系数 β 的消融实验

正则化系数 β 是 FCPC 框架的核心超参数，用于平衡主任务损失与配对约束项的权重占比，直接决定了互约束效应的强度，对模型的收敛性与最终精度有决定性影响。为了明确 β 的最优取值与影响规律，本节设计多场景对照消融实验。

4.3.2.1 实验设置

选取 CIFAR-10 与 CIFAR-100 数据集，覆盖极端异构 ($\alpha = 0.05$) 与高异构 ($\alpha = 0.1$) 两种核心场景，将 β 的取值设置为 $\{0.05, 0.1, 0.2, 0.3\}$ ，固定其他所有超参数与实验环境不变，对比不同 β 取值下模型的最终分类精度，实验结果如图4.3和4.4所示。



 图 4.3 β 消融实验 (CIFAR-10)

 Fig. 4.3 β ablation experiment (CIFAR-10)

4.3.2.2 结果分析

从实验结果可以总结出 β 对模型性能的影响规律：

(1) 当 β 从 0.05 提升至 0.2 时，所有场景下的模型分类精度均呈现持续上升趋势，说明随着约束强度的提升，配对客户端的互约束效应逐渐增强，能够更有效地对齐梯度更新方向，缓解维度坍塌，提升模型性能；

(2) 当 $\beta = 0.2$ 时，所有场景下的模型精度均达到峰值，此时约束强度能够最优地平衡“梯度对齐”与“本地特征学习”的关系，既能够发挥互约束效应的优势，又不会限制模型对本地数据特征的有效学习；

(3) 当 β 从 0.2 继续提升至 0.3 时，所有场景下的模型精度均出现明显下降，说明过强的约束会限制本地模型的优化空间，阻碍模型对本地数据特征的学习，反而导致模型性能下降，出现欠拟合问题。



 图 4.4 β 消融实验 (CIFAR-100)

 Fig. 4.4 β ablation experiment (CIFAR-100)

综合实验结果，本文选取 $\beta = 0.2$ 作为全场景适配的最优默认值，该取值在不同数

据集、不同异构程度的场景下，均能实现最优的约束效果，保证模型的收敛性与分类精度。

4.3.3 差异度量化指标的对比消融实验

为了验证本文提出的 JSDN 双偏斜统一量化指标的优越性，本节设计对照实验，将 JSDN 指标与 3 种常用的分布相似度指标进行对比，包括单一 JSD 指标、欧氏距离、余弦距离，所有对比指标仅能量化标签分布差异，无法覆盖样本量偏斜。

4.3.3.1 实验设置

选取 MNIST、FEMNIST、CIFAR-10 三个数据集，设置 Dirichlet 分布参数 $\alpha = 0.5$ ，固定配对算法、正则化项、训练超参数等所有其他条件完全一致，仅替换客户端配对的差异度量化指标，对比不同指标下模型的最终分类精度，实验结果如表4.3所示。

表 4.3 不同差异度量化指标的性能对比 ($\alpha = 0.5$)

Tab. 4.3 Performance comparison of different dissimilarity quantification metrics ($\alpha = 0.5$)

数据集	JSDN	JSD	欧氏距离	余弦距离
MNIST	91.63%	90.52%	90.27%	90.38%
FEMNIST	88.61%	87.47%	86.30%	86.45%
CIFAR-10	80.08%	78.52%	76.75%	76.70%

4.3.3.2 结果分析

通过可视化图表4.5展示，实验结果表明，本文提出的 JSDN 指标在所有数据集上均取得了较优的分类精度，优于其他 3 种常用的相似度指标。在 CIFAR-10 数据集上，JSDN 指标较单一 JSD 指标提升 1.56 个百分点，较欧氏距离提升 3.33 个百分点，体现出较好的双偏斜刻画能力。

该结果充分验证了 JSDN 指标的核心优势：现有单一指标仅能量化标签分布偏斜，无法覆盖物联网场景中普遍存在的样本量偏斜，导致客户端配对的准确性不足，无法最大化发挥互约束效应；而 JSDN 指标实现了标签分布偏斜与样本量偏斜的统一量化，能够更全面、精准地表征客户端之间的真实异构程度，实现更合理的客户端配对，最终带来更显著的性能提升。




图 4.5 不同量化指标的分类精度对比

Fig. 4.5 Comparison of classification accuracy of different quantitative indicators

4.3.4 极端异构场景鲁棒性分析

真实物联网场景中，不同终端的部署环境差异极大，极易出现极端异构的情况，框架的鲁棒性是落地部署的核心要求。结合前文的核心实验结果，可从三个维度验证 FCPC 框架的鲁棒性：

(1) 异构度变化的鲁棒性：当 Dirichlet 分布参数 α 从 0.5 降至 0.05，异构程度显著提升时，基准 FedAvg 的分类精度从 79.98% 降至 53.74%，衰减幅度达 26.24 个百分点；而 FCPC 框架的精度从 80.28% 降至 63.17%，衰减幅度为 17.11 个百分点，低于基准算法，说明框架对异构程度变化具有较好的鲁棒性，在极端异构场景下仍能保持相对稳定的性能。

(2) 数据集与任务复杂度的鲁棒性：从简单的 MNIST 手写数字分类，到中等复杂度的 CIFAR-10 图像分类，再到高复杂度的 TinyImageNet 细粒度分类，FCPC 框架均能带来稳定的性能提升，没有出现任务复杂度提升后性能失效的问题，说明框架对不同数据集、不同复杂度的任务具有较好的适配性。

(3) 超参数变化的鲁棒性：从 λ 与 β 的消融实验结果可以看出，即使超参数偏离最优值，FCPC 框架仍能保持优于基线算法的性能，没有出现超参数微小变化导致性能断崖式下降的问题，证明框架对超参数的变化具备一定的容忍度，降低了真实场景落地的调优难度。

4.4 通信开销、计算复杂度与边缘资源占用分析

物联网边缘场景中的联邦学习系统通常受到终端算力、存储容量和无线链路带宽的共同约束。因此，除模型精度外，优化方法的通信开销、计算复杂度与端侧资源占用也是衡量其工程可部署性的关键指标。为进一步评估 FCPC 框架的轻量化特性，本节从理论复杂度、模型级通信量估算和智能交通场景下的多规模模型开销分析三个层面对 FCPC 框架的额外开销进行讨论。

设联邦学习系统共有 n 个客户端，分类任务类别数为 C ，全局通信轮次为 T ，模型参数量为 P 。在采用 32 位浮点数传输模型参数的情况下，单个模型的通信大小可表示为：

$$S = 4P \text{ bytes.} \quad (4.1)$$

对于标准 FedAvg，每一轮通信中客户端需要接收一次全局模型并上传一次本地模型更新，因此单客户端每轮主通信量约为 $2S$ ，全系统 T 轮主通信量约为 $O(2TnP)$ 。

FCPC 框架不改变 FedAvg 的全局模型分发与聚合流程，其额外通信主要来自两个部分。第一，在配对初始化阶段，每个客户端需要上传经过本地差分隐私扰动后的标签分布向量与样本量信息，额外通信量为 $O(n(C+1))$ 。相较于模型参数传输，该部分开销通常较小。例如在 CIFAR-10 分类任务中，每个客户端仅需上传 10 维标签分布和 1 个样本量标量，若采用 32 位浮点数表示，仅需约 $4(C+1) = 44 \text{ bytes}$ 。第二，在配对约束训练阶段，客户端需要访问配对客户端上一轮模型权重作为正则化锚点。若直接传输完整模型权重，则该部分的上界为 $O(TnP)$ ；在实际系统中，可通过服务器缓存配对客户端上一轮权重、低频更新锚点、仅约束分类头参数或模型压缩等方式降低该部分开销。因此，FCPC 的异构性量化与配对阶段通信开销较小，而训练阶段的主要额外通信来自配对模型锚点的获取。

在计算复杂度方面，FCPC 的额外服务器端计算主要包括 JSDN 矩阵构建和客户端配对两部分。JSDN 矩阵需要计算所有客户端对之间的标签分布差异和样本量差异，复杂度为 $O(n^2C)$ ；基于最大差异度的贪心配对过程需要在客户端对中选择 JSDN 值最大的配对组合，复杂度约为 $O(n^2)$ 。上述计算均在服务器端完成，不会显著增加边缘客户端的计算负担。客户端侧的额外计算主要来自本地损失函数中的二范数配对正则项，其复杂度与模型参数量线性相关，为 $O(P)$ 。由于 FCPC 不增加额外模型分支，不改变模

型结构，也不改变推理流程，因此其推理阶段参数量和端侧存储占用与原始模型保持一致。

表 4.4 不同联邦学习方法的额外开销对比

Tab. 4.4 Comparison of extra overhead among different federated learning methods

方法	模型结构改变	聚合流程改变	额外客户端计算	额外通信开销
FedAvg	否	否	无	无
FedProx	否	否	$O(P)$	无
MOON	需特征缓存	否	特征提取与对比损失	历史模型/特征相关开销
FCPC	否	否	$O(P)$	$O(n(C+1)) + O(TnP)$ 上界

为进一步给出直观的数量级对比，表4.5列出了不同模型规模下的通信量估算。其中，MLP 交通状态分类器和 TCN 交通流预测模型对应智能交通边缘场景中的典型轻量模型与时序预测模型，MobileNetV2 和 ResNet-18 对应第 3 章和第 4 章图像分类实验中常用的边缘视觉模型与标准视觉模型。可以看出，FCPC 在配对初始化阶段上传的标签分布与样本量信息仅为字节级；训练阶段更需要关注的是配对模型锚点的传输开销。若采用完整模型作为锚点，该开销与模型大小同阶；若采用服务器缓存或仅约束分类头参数，则可进一步降低通信成本。

表 4.5 不同交通边缘模型规模下的通信量估算

Tab. 4.5 Communication estimation under different traffic edge model scales

模型	参数量	单模型大小	FedAvg 单客户端/轮通信	FCPC 元信息上传	完整锚点额外通信
MLP 交通状态分类器	约 263K	约 1.00 MB	约 2.00 MB	16 B	约 1.00 MB
TCN 交通流预测模型	约 820K	约 3.13 MB	约 6.26 MB	16 B	约 3.13 MB
MobileNetV2	约 3.5M	约 13.4 MB	约 26.8 MB	CIFAR-10: 44 B	约 13.4 MB
ResNet-18	约 11.7M	约 44.6 MB	约 89.2 MB	CIFAR-10: 44 B	约 44.6 MB

综上，FCPC 的额外开销主要集中在服务器端 JSDN 配对和训练阶段配对锚点的获取，不增加模型参数量，不改变推理阶段资源占用，也不改变全局聚合流程。对于资源受限的物联网边缘终端，FCPC 具备较好的轻量化部署特性；在大模型场景下，后续可结合服务器缓存、低频锚点更新、分类头约束和模型压缩等方式进一步降低配对锚点通信开销。

4.5 面向智能交通场景的部署设计与可行性分析

本章前序章节已通过系统实验验证了 FCPC 框架的正交兼容性、模块有效性与极端场景鲁棒性，并补充分析了通信、计算与资源占用开销。本节以智能交通车路协同系统

为核心载体，进一步给出 FCPC 框架的场景化部署设计与可行性分析。

4.5.1 智能交通 IoT 场景的设备与双偏斜数据特征

智能交通系统是物联网技术落地的核心垂直领域，其核心业务场景（交通流量预测、信号配时优化、突发事件识别、拥堵治理）高度依赖多源边缘终端的协同数据建模^[62-65]，而数据隐私合规与多终端数据异构性，是制约其智能化升级的两大核心瓶颈。

该场景的核心终端设备分为三类，均具备典型的物联网边缘节点特性，如图4.6：

路侧单元（Road Side Unit, RSU）与交通监控终端：部署于城市路口、高速路段、乡村道路等不同区位，负责采集路段交通流量、车速、拥堵状态等核心数据，设备算力、存储资源受限，仅能支撑轻量化的本地模型训练^[66]；

车载单元（On Board Unit, OBU）：安装于货运车辆、私家乘用车、公交车辆等不同类型的交通工具，负责采集车辆行驶状态、出行轨迹等数据，设备在线时长、采集频率差异极大；

交通信号控制器：部署于路口信号机，负责采集信号配时状态、路口通行效率等数据，是交通管控的核心执行终端^[67]。




图 4.6 智能交通 IoT 场景

Fig. 4.6 Intelligent transportation IoT scenarios

上述终端设备的部署环境、采集目标、运行模式存在本质差异，天然产生了标签分

布偏斜与样本量偏斜共存的双偏斜非 IID 数据，其产生根源可分为两个维度：

- 标签分布偏斜根源：不同区位的终端采集的数据标签分布存在显著差异。城市核心路口的 RSU，高峰时段采集的数据中，拥堵类标签样本占比可达 80% 以上；而郊区路段的 RSU，采集的数据中正常通行类标签占比超过 90%^[68]。同时，货运车辆 OBU 采集的高速稳定行驶类数据，与城市乘用车 OBU 采集的频繁启停类数据，在标签空间上存在本质差异，进一步放大了标签分布的异构性。
- 样本量偏斜根源：不同终端的运行时长、采集频率存在数量级差异。城市核心路口的交通监控终端 24 小时不间断运行，单日可产生数十万条有效样本；而乡村路段的低功耗监测终端，仅在车辆经过时触发采集，单日有效样本量不足千条^[69]。同时，高频运行的公交车辆 OBU，样本量远高于间歇出行的私家车辆 OBU，形成了显著的样本量偏斜。

这种双偏斜非 IID 数据特性，导致传统联邦学习算法在该场景中出现严重的梯度发散、模型泛化能力差等问题，无法支撑高精度的交通状态预测与管控优化，而 FCPC 框架的轻量化、即插即用、双偏斜适配的核心特性，与该场景的落地需求高度匹配。

4.5.2 FCPC 框架的场景化部署架构与全流程

FCPC 框架在智能交通 IoT 场景的架构如图 4.7 所示，整体采用“云-边-端”三级协同架构。




图 4.7 FCPC 交通应用架构

Fig. 4.7 FCPC transportation application architecture

基于上述架构，FCPC 框架在该场景的部署流程分为 4 个核心步骤，与本文第 3 章提出的基础框架逻辑保持一致，同时针对智能交通场景的业务特性进行适配：

(1) 终端侧隐私保护数据预处理：各 RSU、OBU、交通信号控制器作为联邦学习的客户端，在本地完成数据标签统计与样本量核算，通过本文提出的本地差分隐私 (LDP) 机制，对标签分布与样本量数据添加噪声扰动后，仅将扰动后的信息上传至云端调度中心，全程不泄露任何原始交通数据，完全符合《数据安全法》对交通敏感数据的隐私保护要求。

(2) 云端 JSDN 矩阵计算与客户端配对：云端调度中心基于各终端上传的扰动数据，计算全系统终端的 JSDN 矩阵，通过本文提出的客户端配对算法，优先将数据分布差异最大的终端进行配对。例如将城市核心路口的拥堵数据 RSU 与郊区路段的畅通数据 RSU 配对，将高速货运车辆 OBU 与城市乘用车 OBU 配对，最大化利用高差异度终端之间的互约束效应。

(3) 带配对约束的边缘协同训练：云端将全局初始模型与配对序列下发至各边缘终端，终端在本地训练过程中，在原有交通预测模型的损失函数中加入 FCPC 配对正则化项，通过配对终端的互约束效应，对齐梯度更新方向，缓解双偏斜数据带来的维度坍塌问题。训练过程中，配对终端之间无需交互原始数据；若采用完整模型权重作为配对锚点，则会引入与模型规模同阶的额外通信量，实际部署时可结合云端缓存、低频锚点更新或分类头约束等策略降低带宽压力。

(4) 全局模型聚合与边缘推理部署：各终端完成本地训练后，将本地模型权重上传至云端，云端采用标准 FedAvg 加权平均策略完成全局模型聚合，将更新后的全局模型下发至各边缘终端，用于本地的交通流量预测、信号配时优化等推理任务。整个流程无需修改现有联邦学习系统的核心聚合逻辑，具备集成至已有车路协同联邦学习平台的可行性。

4.5.3 智能交通场景仿真实验

本文进一步构建智能交通场景下的多规模边缘模型开销分析，对 FCPC 框架在不同模型规模下的通信开销与资源占用进行补充评估。实验场景模拟 12 个交通边缘客户端，包括城市核心路口 RSU、郊区路段 RSU、公交 OBU 和私家车 OBU，并基于不同标签分布和样本量配置构造双偏斜 Non-IID 场景。为避免过小规模模型导致开销低估，本文选取两类更接近实际边缘交通任务的模型作为分析对象：一类是 MLP 交通状态分类器，用于交通状态识别等轻量分类任务；另一类是 TCN 交通流预测模型，用于短时交通流

量预测等时序建模任务。需要说明的是，该分析采用场景驱动的合成交通特征设定和模型参数规模估算，目的在于量化不同模型规模下 FCPC 在典型交通边缘场景中的额外通信与资源开销，并不等同于真实道路数据或真实设备实测。

从表4.5可以看出，在 MLP 交通状态分类器和 TCN 交通流预测模型两类边缘交通模型下，单模型大小分别约为 1.00 MB 和 3.13 MB，对应 FedAvg 单客户端每轮上下行通信量约为 2.00 MB 和 6.26 MB。FCPC 在配对初始化阶段仅需上传标签分布与样本量元信息，在 3 类交通状态标签设置下，每个客户端上传 4 个 32 位浮点数，额外通信量约为 16 B，相较于模型参数传输处于较低数量级。训练阶段若采用完整模型权重作为配对锚点，则会额外引入与模型大小同阶的通信量；因此在实际部署中，可结合服务器缓存、低频锚点更新、分类头约束或模型压缩等策略降低配对锚点传输成本。

表 4.6 智能交通场景下 FCPC 的资源开销估算

Tab. 4.6 Resource overhead estimation of FCPC in the intelligent transportation scenario

模型	方法	额外元信息通信量	完整锚点额外通信/轮	推理阶段参数增加	额外客户端计算复杂度
MLP 交通状态分类器	FedAvg	0	0	0	无
MLP 交通状态分类器	FCPC	16 B/客户端	约 1.00 MB/客户端	0	$O(P)$
TCN 交通流预测模型	FedAvg	0	0	0	无
TCN 交通流预测模型	FCPC	16 B/客户端	约 3.13 MB/客户端	0	$O(P)$

从表4.6可以看出，FCPC 不改变原始交通模型结构，也不增加推理阶段参数量，因此模型部署后的端侧存储占用和推理计算量与 FedAvg 保持一致。FCPC 的额外开销主要来自两个部分：其一是配对初始化阶段上传的标签分布与样本量元信息，该部分在 3 类交通状态标签下仅为 16 B/客户端；其二是训练阶段配对模型锚点的获取，若直接传输完整模型权重，则 MLP 交通状态分类器和 TCN 交通流预测模型分别会带来约 1.00 MB/客户端/轮和 3.13 MB/客户端/轮的额外通信上界。由于该部分开销与模型大小同阶，实际部署时可采用服务器端缓存、低频锚点同步、仅约束分类头参数或压缩传输等方式进一步降低通信压力。

总体来看，FCPC 在边缘交通模型上的主要优势在于不改变全局聚合流程、不增加模型结构和推理阶段资源占用；其需要重点控制的是训练阶段配对锚点的模型级通信开销。相比极小规模分类器，MLP 交通状态分类器和 TCN 交通流预测模型能够更合理地反映智能交通边缘任务中的模型规模和通信量级，也更适合用于支撑本文关于边缘资源占用的分析。

4.5.4 场景落地适配优势与应用价值

FCPC 框架在智能交通 IoT 场景的落地应用，主要具备以下四方面适配优势：

(1) 即插即用的低改造成本优势：框架无需修改现有车路协同联邦学习系统的核心架构、聚合逻辑与模型设计，仅需新增轻量化的配对模块与正则化项，即可在较低改造成本下提升非 IID 场景中的模型性能。

(2) 双偏斜数据的强适配优势：框架通过 JSDN 统一量化指标，精准刻画智能交通场景的标签与样本量双偏斜特性，通过高差异度终端配对约束，有效缓解异构数据带来的模型性能衰减，在不同路段、不同终端的异构场景中均能保持稳定的预测精度。

(3) 边缘设备的轻量化适配优势：框架仅在本地训练阶段引入配对正则化项，额外计算主要与模型参数量线性相关，不增加推理阶段参数量和存储占用，可在算力、存储资源受限的路侧与车载终端上运行。

(4) 全流程的隐私保护优势：框架从终端数据上传到协同训练全流程，均采用本地差分隐私机制进行隐私保护，全程无原始数据的跨终端流转，完全符合交通数据的隐私合规要求，消除了数据共享的安全顾虑。

从工程应用价值来看，基于 FCPC 框架训练的全局交通预测模型，有助于提升短临交通流量预测与拥堵状态识别的稳定性，为交通信号动态配时、出行路线诱导提供模型支撑，从而服务于路网通行效率提升与拥堵治理^[25, 70]。同时，框架的即插即用特性，可适配智能交通系统的持续扩容需求，新增路侧与车载终端可在较少改造的条件下接入联邦学习系统，具备进一步扩展应用的潜力。

4.6 本章小结

本章作为本文的第二研究工作，围绕 FCPC 框架在物联网场景中的兼容性、模块有效性、鲁棒性和部署开销展开分析，与第一研究工作形成了“基础方法设计-工程可行性分析”的递进关系。首先，明确了本章的核心研究动机与优化目标，针对框架应用中的兼容性、模块有效性、场景鲁棒性和部署开销问题，规划了研究内容；其次，通过多数据集、多基线算法的对照实验，系统验证了 FCPC 框架与主流联邦学习算法的正交兼容性，说明其在极端异构场景下可为基线算法带来 3.5%-9.4% 的稳定性能提升；随后，通过多组消融实验，拆解了框架核心模块的有效性，明确了 JSDN 权重参数 $\lambda = 0.3$ 、正

则化系数 $\beta = 0.2$ 的默认取值，验证了框架在极端异构场景下的鲁棒性；最后，补充分析了 FCPC 框架的通信开销、计算复杂度与边缘资源占用，并以智能交通车路协同 IoT 场景为载体，给出了场景化部署架构、多规模边缘模型开销分析和局限性说明。

本章的研究内容说明，FCPC 框架在保持原有联邦学习聚合逻辑的基础上，能够兼顾非 IID 场景下的性能提升与较低的端侧资源改造成本，为后续在物联网边缘场景中的进一步实验验证和工程部署提供了参考。

第五章 总结与展望

5.1 本文工作总结

本文针对物联网场景中，标签分布与样本量双偏斜非 IID 数据导致的联邦学习模型性能衰减、落地适配性差的核心问题，以“理论分析-方法设计-性能验证-开销分析-场景适配”为研究脉络，开展了两项递进式研究工作，形成了一套轻量级、即插即用的双偏斜非 IID 联邦学习优化方案。

本文的第一项研究工作，聚焦双偏斜非 IID 场景下的模型性能衰减问题，完成了异构性量化方法与基础优化框架设计。首先通过 4 组对照预实验，挖掘并验证了联邦学习客户端间互约束效应与数据分布差异度的正相关关系，明确了双偏斜非 IID 数据导致模型性能衰减的核心机理是维度坍塌与梯度更新方向发散；其次针对现有异构性量化指标无法覆盖双偏斜场景的核心缺口，设计了 JSDN 双偏斜统一量化指标，实现了标签分布偏斜与样本量偏斜的整体表征；随后基于 JSDN 指标设计了最大化分布差异的客户端配对算法，结合轻量级配对正则化项，构建了 FCPC 基础框架，无需修改联邦学习核心聚合逻辑，具备轻量化、即插即用的核心特性；最后通过收敛性理论分析讨论了框架的收敛稳定性，并通过多数据集对照实验验证了框架的核心性能：在极端双偏斜异构场景 ($\alpha = 0.05$) 下，FCPC 在 CIFAR-10 数据集上取得 63.17% 的 Top-1 精度，较基准 FedAvg 提升 9.4 个百分点。

本文的第二项研究工作，聚焦基础框架的工程适配性问题，完成了兼容性验证、鲁棒性分析、部署开销分析与场景化设计。首先通过多数据集、多基线算法的系统对照实验，验证了 FCPC 框架与现有主流联邦学习算法的正交兼容性，框架可集成至 FedAvg、FedProx、MOON 等 5 种主流算法中，在全异构度场景下带来 3.5%-9.4% 的稳定性能提升，验证了其即插即用的核心优势；其次通过多组消融实验，拆解了框架核心模块的独立贡献，明确了 JSDN 权重参数 $\lambda = 0.3$ 、正则化系数 $\beta = 0.2$ 的默认取值，为场景化应用中的超参数调优提供依据；随后通过极端异构场景实验，验证了框架的鲁棒性，明确了框架的适用边界；最后补充通信开销、计算复杂度与边缘资源占用分析，并以智能交通车路协同 IoT 场景为核心载体，完成了 FCPC 框架的场景化部署架构设计、轻量级仿真支撑与局限性说明。

本文的核心创新点可总结为三点：其一，揭示了客户端数据分布差异与互约束效应的正相关关系，设计了轻量级配对正则化机制，有效缓解了非 IID 场景下的维度坍塌问题；其二，提出了 JSDN 双偏斜异构性统一量化指标，弥补了现有指标难以同时覆盖标签与样本量偏斜的不足；其三，构建了即插即用的 FCPC 框架，无需修改现有联邦学习核心架构，额外计算主要与模型参数量线性相关，与物联网边缘节点的资源受限特性较为匹配。

5.2 未来研究展望

本文提出的 FCPC 框架，已通过系统的理论分析与实验验证，证明了其在双偏斜非 IID 物联网场景中的有效性与落地适配性，但受限于研究周期与实验条件，仍存在可进一步拓展与优化的空间，本文基于已发表成果的未来研究方向，结合物联网联邦学习的行业发展趋势，提出三个合理的延伸研究方向，所有拓展均不否定本文现有成果的核心价值。

第一，设计面向动态物联网环境的参数自适应调整机制。本文目前采用固定的 JSDN 权重参数 λ 与正则化系数 β ，适配静态的异构场景。而真实物联网场景中，终端在线状态、数据分布、样本量均会随时间动态变化，固定参数无法适配动态异构环境。未来可基于终端数据分布的实时变化特征，设计 λ 与 β 的自适应动态调整机制^[71, 72]，无需人工调参即可实现全时段的最优约束效果，进一步提升框架在动态物联网场景中的适配性。

第二，拓展框架对全类型异构场景的适配能力。本文目前聚焦物联网场景中最普遍的标签分布与样本量双偏斜问题，未来可进一步拓展 JSDN 量化指标的特征维度，纳入特征分布偏斜、概念漂移^[73]、模型异构等更复杂的异构类型，优化客户端配对机制与正则化约束逻辑^[74]，使框架能够适配全类型异构场景，进一步拓展框架的适用边界。

第三，完成真实或半实物场景的落地验证与优化。本文目前的验证场景以横向联邦的跨终端物联网场景和轻量级仿真分析为主，未来可将 FCPC 框架拓展至跨机构的纵向联邦学习场景，针对工业质检、金融风控、医疗数据协同等对隐私要求严苛的场景^[75]，完成框架的适配优化、真实数据验证与半实物平台测试，进一步挖掘框架的工业应用价值。

参考文献

- [1] An Z, Yu X, Wang C, et al. Embodied intelligence: Recent advances and future perspectives[J/OL]. The Innovation Informatics, 2025, 1(1): 100008. <https://www.the-innovation.org/informatics/article/id/68da75b1eaedd90f412200cb>. DOI: 10.59717/j.xinn-inform.2025.100008.
- [2] Zhang Z, Wu L, Jin J, et al. Secure Federated Learning for Cloud-Fog Automation: Vulnerabilities, Challenges, Solutions, and Future Directions[J]. IEEE Transactions on Industrial Informatics, 2025, 21(5): 3528–3540. DOI: 10.1109/TII.2025.3528569.
- [3] Guo J, Liu Z, Tian S, et al. TFL-DT: A trust evaluation scheme for federated learning in digital twin for mobile networks[J]. IEEE Journal on Selected Areas in Communications, 2023, 41(11): 3548–3560.
- [4] Xie Q, Jiang S, Jiang L, et al. Efficiency optimization techniques in privacy-preserving federated learning with homomorphic encryption: A brief survey[J]. IEEE Internet of Things Journal, 2024, 11(14): 24569–24580.
- [5] 俞浩, 范菁, 孙伊航. 异构联邦学习在无人系统中的研究综述[J]. 计算机应用研究, 2025, 42(3).
- [6] Li X, Zhao H, Deng W. IOFL: Intelligent-optimization-based federated learning for Non-IID data[J]. IEEE Internet of Things Journal, 2024, 11(9): 16693–16699.
- [7] Solans D, Heikkila M, Vitaletti A, et al. Non-iid data in federated learning: A systematic review with taxonomy, metrics, methods, frameworks and future directions[J]. arXiv preprint arXiv:2411.12377, 2024.
- [8] Li Q, Diao Y, Chen Q, et al. Federated learning on non-iid data silos: An experimental study[C]//2022 IEEE 38th international conference on data engineering (ICDE). IEEE, 2022: 965–978.
- [9] Liu B, Lv N, Guo Y, et al. Recent advances on federated learning: A systematic survey [J]. Neurocomputing, 2024: 128019.
- [10] Ye M, Fang X, Du B, et al. Heterogeneous federated learning: State-of-the-art and research

- challenges[J]. *ACM Computing Surveys*, 2023, 56(3): 1–44.
- [11] Zhao Y, Li M, Lai L, et al. Federated learning with non-iid data[J]. *arXiv preprint arXiv:1806.00582*, 2018.
- [12] Hu K, Xiang L, Tang P, et al. Feature norm regularized federated learning: utilizing data disparities for model performance gains[C]//*Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence*. 2024: 4136–4146.
- [13] Li T, Sahu A K, Zaheer M, et al. Federated optimization in heterogeneous networks[J]. *Proceedings of Machine learning and systems*, 2020, 2: 429–450.
- [14] Li Q, He B, Song D. Model-contrastive federated learning[C]//*Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2021: 10713–10722.
- [15] Jin C, Chen X, Gu Y, et al. FedDyn: A dynamic and efficient federated distillation approach on Recommender System[C]//*2022 IEEE 28th international conference on parallel and distributed systems (ICPADS)*. IEEE, 2023: 786–793.
- [16] Jiang Z, Xu J, Zhang S, et al. Fedcfa: Alleviating simpson’s paradox in model aggregation with counterfactual federated learning[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*: 39. 2025: 17662–17670.
- [17] Xu Y, Li Y, Luo H, et al. FBLG: A Local Graph Based Approach for Handling Dual Skewed Non-IID Data in Federated Learning[C]//*Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence, IJCAI-24*, K. Larson, Ed. International Joint Conferences on Artificial Intelligence Organization: 8. 2024: 5289–5297.
- [18] Thapa C, Arachchige P C M, Camtepe S, et al. Splitfed: When federated learning meets split learning[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*: 36. 2022: 8485–8493.
- [19] Wu W, Li M, Qu K, et al. Split learning over wireless networks: Parallel design and resource management[J]. *IEEE Journal on Selected Areas in Communications*, 2023, 41(4): 1051–1066.
- [20] Lin Z, Qu G, Wei W, et al. Adaptsfl: Adaptive split federated learning in resource-constrained edge networks[J]. *arXiv preprint arXiv:2403.13101*, 2024.

- [21] Jiang W, Han H, Zhang Y, et al. Federated split learning for sequential data in satellite–terrestrial integrated networks[J]. *Information Fusion*, 2024, 103: 102141.
- [22] Almalik F, Alkhunaizi N, Almakky I, et al. Fesvibs: Federated split learning of vision transformer with block sampling[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2023: 350–360.
- [23] Liu X, Song Y, Li X, et al. ED-ViT: Splitting Vision Transformer for Distributed Inference on Edge Devices[J]. *arXiv preprint arXiv:2410.11650*, 2024.
- [24] Truong-Tuan K, Van-Thien L, Nguyen-Khanh T, et al. Developing a Face Recognition System Using Vision Transformer and Federated Learning[C]//2024 International Conference on Advanced Technologies for Communications (ATC). IEEE, 2024: 528–533.
- [25] Thwal C M, Nguyen M N, Tun Y L, et al. OnDev-LCT: On-Device Lightweight Convolutional Transformers towards federated learning[J]. *Neural Networks*, 2024, 170: 635–649.
- [26] 何帆, 王勇, 杨静, 等. 面向边缘计算场景的个性化联邦学习综述[J]. *通信学报*, 2025, 46(7).
- [27] Tong Z, Wang J, Hou X, et al. Blockchain-based trustworthy and efficient hierarchical federated learning for UAV-enabled IoT networks[J]. *IEEE Internet of Things Journal*, 2024, 11(21): 34270–34282.
- [28] Liu J, Huo Y, Qu P, et al. Fedcd: A hybrid federated learning framework for efficient training with iot devices[J]. *IEEE Internet of Things Journal*, 2024, 11(11): 20040–20050.
- [29] Chen Z, Peng J, Kang J, et al. FedGroup-Prune: IoT device amicable and training-efficient federated learning via combined group lasso sparse model pruning[J]. *IEEE Internet of Things Journal*, 2024.
- [30] Jiang L, Liu Y, Tian H, et al. Resource-efficient federated learning and DAG blockchain with sharding in digital-twin-driven industrial IoT[J]. *IEEE Internet of Things Journal*, 2024, 11(10): 17113–17127.
- [31] Wei X X, Huang H. Edge devices clustering for federated visual classification: A feature norm based framework[J]. *IEEE Transactions on Image Processing*, 2023, 32: 995–1010.

- [32] Luo M, Chen F, Hu D, et al. No fear of heterogeneity: Classifier calibration for federated learning with non-iid data[J]. Advances in Neural Information Processing Systems, 2021, 34: 5972–5984.
- [33] Wang H, Yurochkin M, Sun Y, et al. Federated Learning with Matched Averaging[C]// International Conference on Learning Representations. 2020.
- [34] Lin T, Kong L, Stich S U, et al. Ensemble distillation for robust model fusion in federated learning[J]. Advances in neural information processing systems, 2020, 33: 2351–2363.
- [35] Cao K, Cui Y, Xu R, et al. Personalized Federated Learning for Green Industrial IoT[J]. IEEE Transactions on Industrial Informatics, 2025.
- [36] Reddi S, Charles Z, Zaheer M, et al. Adaptive federated optimization[J]. arXiv preprint arXiv:2003.00295, 2020.
- [37] Cao K, Cui Y, Xu R, et al. Personalized Federated Learning for Green Industrial IoT [J]. IEEE Transactions on Industrial Informatics, 2025, 21(8): 6114–6125. DOI: 10.1109/TII.2025.3558340.
- [38] Dai C, Lu S, Wang P, et al. Client Selection in Federated Learning for Industry 5.0: A Heuristic-Guided Pointer Network Reinforcement Learning Approach[J]. IEEE Transactions on Industrial Informatics, 2025: 1–11. DOI: 10.1109/TII.2025.3593950.
- [39] Guo S, Chen H, Liu Y, et al. Heterogeneous Federated Learning Framework for IIoT Based on Selective Knowledge Distillation[J]. IEEE Transactions on Industrial Informatics, 2025, 21(2): 1078–1089. DOI: 10.1109/TII.2024.3452229.
- [40] 温泽诚, 陈磊. 联邦学习综述[J]. Computer Science and Application, 2025, 15: 102.
- [41] Tang J, Fan K, Xie W, et al. BTV-CMAB: A bi-directional trust verification-based combinatorial multiarmed bandit scheme for mobile crowdsourcing[J]. IEEE Internet of Things Journal, 2023, 11(2): 1925–1938.
- [42] Zeng P, Liu A, Xiong N N, et al. TD-MDB: A truth-discovery-based multidimensional bidding strategy for federated learning in industrial IoT systems[J]. IEEE Internet of Things Journal, 2023, 11(3): 4274–4288.
- [43] McMahan B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics. PMLR, 2017:

- 1273–1282.
- [44] Zhang J, Li Z, Li B, et al. Federated learning with label distribution skew via logits calibration[C]//International Conference on Machine Learning. PMLR, 2022: 26311–26329.
- [45] Du Z, Sun J, Li A, et al. Rethinking normalization methods in federated learning[C]//Proceedings of the 3rd International Workshop on Distributed Machine Learning. 2022: 16–22.
- [46] Dwork C, McSherry F, Nissim K, et al. Calibrating noise to sensitivity in private data analysis[C]//Theory of Cryptography: Third Theory of Cryptography Conference, TCC 2006, New York, NY, USA, March 4-7, 2006. Proceedings 3. Springer, 2006: 265–284.
- [47] Duchi J C, Jordan M I, Wainwright M J. Local privacy and minimax estimation: Sharp rates for probability estimation[C]//Advances in Neural Information Processing Systems. 2013: 1529–1537.
- [48] Wang T, Blocki J, Li N, et al. Locally differentially private protocols for frequency estimation[C]//26th USENIX Security Symposium (USENIX Security 17). 2017: 729–745.
- [49] McSherry F D. Privacy integrated queries: an extensible platform for privacy-preserving data analysis[C]//Proceedings of the 2009 ACM SIGMOD International Conference on Management of data. 2009: 19–30.
- [50] Shi Y, Liang J, Zhang W, et al. Towards Understanding and Mitigating Dimensional Collapse in Heterogeneous Federated Learning[C]//ICLR. 2023.
- [51] Lin J. Divergence measures based on the Shannon entropy[J]. IEEE Transactions on Information theory, 1991, 37(1): 145–151.
- [52] Van Erven T, Harremoës P. Rényi divergence and Kullback-Leibler divergence[J]. IEEE Transactions on Information Theory, 2014, 60(7): 3797–3820.
- [53] Karimireddy S P, Kale S, Mohri M, et al. Scaffold: Stochastic controlled averaging for federated learning[C]//International conference on machine learning. PMLR, 2020: 5132–5143.
- [54] Wang J, Liu Q, Liang H, et al. Tackling the objective inconsistency problem in

- heterogeneous federated optimization[J]. *Advances in neural information processing systems*, 2020, 33: 7611–7623.
- [55] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016: 770–778.
- [56] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018: 4510–4520.
- [57] Robbins H, Monro S. A stochastic approximation method[J]. *The annals of mathematical statistics*, 1951: 400–407.
- [58] Cubuk E D, Zoph B, Mane D, et al. Autoaugment: Learning augmentation policies from data[J]. *arXiv preprint arXiv:1805.09501*, 2018.
- [59] Han P, Wang S, Leung K K. Adaptive gradient sparsification for efficient federated learning: An online learning approach[C]//*2020 IEEE 40th international conference on distributed computing systems (ICDCS)*. IEEE, 2020: 300–310.
- [60] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11): 2278–2324.
- [61] Krizhevsky A, Hinton G, others. Learning multiple layers of features from tiny images [M]. Toronto, ON, Canada, 2009.
- [62] Zhang Y, Wang X, Wang P, et al. Modeling Spatio-Temporal Mobility Across Data Silos via Personalized Federated Learning[J]. *IEEE Transactions on Mobile Computing*, 2024.
- [63] Liu Q, Sun S, Liu M, et al. Online spatio-temporal correlation-based federated learning for traffic flow forecasting[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2024.
- [64] Kaur G, Grewal S K, Jain A. Federated Learning based Spatio-Temporal framework for real-time traffic prediction[J]. *Wireless Personal Communications*, 2024, 136(2): 849–865.
- [65] Feng J, Du C, Mu Q. Traffic Flow Prediction Based on Federated Learning and Spatio-Temporal Graph Neural Networks[J]. *ISPRS International Journal of Geo-Information*, 2024, 13(6): 210.

- [66] Wu C, Wang H, Zhang X, et al. Spatio-temporal Heterogeneous Federated Learning for Time Series Classification with Multi-view Orthogonal Training[C]//Proceedings of the 32nd ACM International Conference on Multimedia. 2024: 2613–2622.
- [67] Zhong L, Zeng J, Wang Z, et al. SCFL: Spatio-temporal consistency federated learning for next POI recommendation[J]. Information Processing & Management, 2024, 61(6): 103852.
- [68] Gahlan N, Sethia D. AFLEMP: Attention-based federated learning for emotion recognition using multi-modal physiological data[J]. Biomedical Signal Processing and Control, 2024, 94: 106353.
- [69] Liu Y, Xue J, Li D, et al. Image recognition based on lightweight convolutional neural network: Recent advances[J]. Image and Vision Computing, 2024: 105037.
- [70] Majcherczyk N, Srishankar N, Pincioli C. Flow-fl: Data-driven federated learning for spatio-temporal predictions in multi-robot systems[C]//2021 IEEE international conference on robotics and automation (ICRA). IEEE, 2021: 8836–8842.
- [71] Li T, Hu S, Beirami A, et al. Ditto: Fair and robust federated learning through personalization[C]//International conference on machine learning. PMLR, 2021: 6357–6368.
- [72] Mei Y, Guo P, Zhou M, et al. Resource-adaptive federated learning with all-in-one neural composition[J]. Advances in Neural Information Processing Systems, 2022, 35: 4270–4284.
- [73] Mawuli C B, Che L, Kumar J, et al. Fedstream: Prototype-based federated learning on distributed concept-drifting data streams[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2023, 53(11): 7112–7124.
- [74] Li L, Lu W, Pedrycz W. An Adaptive Federated Fuzzy C-Means Clustering With Nonindependently and Identically Distributed Data[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2025.
- [75] Gan X, Lu P, Gan S, et al. Fed-BRMC: Byzantine-Robust Federated Learning via Dual-Model Contrastive Detection[C]//2024 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2024: 4297–4303.

攻读硕士学位期间取得的学术成果

- [1] FCPC: A Dissimilarity-Aware Plug-and-Play Federated Learning Framework for Non-IID IoT Systems. **IEEE Transactions on Industrial Informatics**. (中科院一区大修)
- [2] 安徽省分布式系统与网络设计大赛二等奖
- [3] 第三届长三角研究生智慧城市创意设计大赛一等奖

致 谢

时光荏苒，三年的研究生生涯转瞬即逝。回首这段充实而珍贵的求学时光，心中满是收获与感恩。在此，我谨向所有给予我指导、支持与陪伴的师长、同窗与家人，致以最诚挚的谢意。

首先，我衷心感谢我的导师陈彦明教授。在研究生阶段的学习与科研中，陈老师以严谨的治学态度、深厚的学术素养和耐心细致的指导，引领我逐步走进科研领域。每当我在研究方向、论文写作或实验设计中遇到困惑，陈老师总能及时为我指点迷津、理清思路，帮助我突破瓶颈。陈老师求真务实的科研精神与认真负责的处事态度，让我受益终身。在此，谨向陈老师致以最崇高的敬意，祝愿老师身体健康、工作顺利、学术之路再攀高峰。

其次，感谢课题组全体师生。感谢各位师兄师姐在科研中给予我的无私帮助与经验分享，无论是实验调试、代码实现还是论文撰写，他们都倾囊相授，让我少走了大量弯路。同时也感谢师弟师妹们为团队带来的活力与新思路，让科研生活更加充实而有趣。祝愿课题组所有同学前程似锦、未来可期，在各自的领域不断突破、再创佳绩。

同时，感谢三年来朝夕相伴的室友与同窗。在科研压力与日常学习中，是他们的陪伴、鼓励与支持，让我始终保持积极向上的心态。彼此扶持、共同进步的时光，成为研究生生涯中温暖而难忘的回忆。愿我们友谊长存，在人生新的阶段各自绽放光彩。

此外，我最想感谢的是我的家人。父母始终是我坚实的后盾，他们默默付出、无条件支持，让我能够心无旁骛地投入学习与科研，顺利完成学业。这份恩情，我将永远铭记于心。

最后，感谢开源社区与所有科研工作者的无私分享。正是开源工具、公开数据集与前沿成果的支撑，为我的研究提供了重要基础，让我在探索之路上不断前行。

研究生阶段的结束，是终点，更是新的起点。未来，我将带着这段时光赋予我的成长与力量，继续脚踏实地、砥砺前行，不负师长教诲、不负家人期盼、不负自己初心。

愿所有关心、支持与帮助过我的人，平安顺遂、万事胜意。